

大数据技术基础综合设计报告

班级：计算机 2101

学号：2106410116

姓名：李洋

Python 爬取大连晚报首页版面

一：分析与设计

1.需求分析：

便于个人对晚报的阅读选择

2.功能设计：

这段代码用于从大连日报网站获取新闻标题。脚本首先构建了目标 URL，然后使用 Requests 库发送 HTTP GET 请求以获取网页内容，接着使用 BeautifulSoup 库解析 HTML 页面，最后提取新闻标题并将其打印出来。

二：系统实现

1. 程序实现

```
# -*- coding: utf-8 -*-  
"""
```

Created on Wed Oct 18 19:24:41 2023

```
@author: 86178  
"""
```

```
import requests  
from bs4 import BeautifulSoup  
import time  
#从 beautifulsoup4 库中引入 BeautifulSoup 类，注意大小写  
import bs4  
headers = {  
    'User-Agent': 'Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36  
(KHTML, like Gecko) Chrome/89.0.4389.114 Safari/53'  
}  
url='http://szb.dltv.cn/epaper/dlr/pc/layout/'  
try:
```

```
    t=time.localtime()  
    y=str(t.tm_year)
```

```

m=str(t.tm_mon)
d=str(t.tm_mday-1)
url1=url+y+m+'/'+d+'/node_A01.html'

r=requests.get(url1,timeout=30,headers=headers)
r.raise_for_status()
r.encoding=r.apparent_encoding
html=r.text

soup=BeautifulSoup(html,'html.parser')

li_all = soup.find_all('h3')
print("开始爬取\n")
num=0
for x in li_all:
    d=x.find('a')
    if(num>0):
        print("大连日报今日新闻: ",num,d.text)
        num=num+1
    print("爬取结束!! ")
except:
    print('获取网页信息失败')

```

2. 运行与测试

```

5 @author: 86178
6 """
7
8
9 import requests
10 from bs4 import BeautifulSoup
11 import time
12 #从beautifulsoup4库中引入BeautifulSoup类, 注意大小写
13 import bs4
14 headers = {
15     'User-Agent': 'Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/89.0.4389.114 Safari/53'
16 }
17 url='http://szb.dltv.cn/epaper/dlrb/pc/layout/'
18 try:
19
20     t=time.localtime()
21     y=str(t.tm_year)
22     m=str(t.tm_mon)
23     d=str(t.tm_mday-1)
24     url1=url+y+m+'/'+d+'/node_A01.html'
25
26     r=requests.get(url1,timeout=30,headers=headers)
27     r.raise_for_status()
28     r.encoding=r.apparent_encoding
29     html=r.text
30
31     soup=BeautifulSoup(html,'html.parser')
32
33     li_all = soup.find_all('h3')
34     print("开始爬取\n")
35     num=0
36     for x in li_all:
37         d=x.find('a')
38         if(num>0):
39             print("大连日报今日新闻: ",num,d.text)
40             num=num+1
41         print("爬取结束!! ")
42 except:
43     print('获取网页信息失败')

```

运行成功

大连日报今日新闻： 1 习近平将出席第三届“一带一路”国际合作高峰论坛开幕式并发表主旨演讲
大连日报今日新闻： 2 《习近平谈“一带一路”》多语种版图书首发式在京举行
大连日报今日新闻： 3 筑就通向美好未来的阳光大道
大连日报今日新闻： 4 中共中央印发《全国干部教育培训规划（2023—2027年）》
大连日报今日新闻： 5 创造属于我们这个时代的新文化
大连日报今日新闻： 6 《大连市外商投资促进条例》《大连市城镇燃气管理条例》2023年12月1日起施行
大连日报今日新闻： 7 以重大项目建设为牵引 携手谱写高水平务实合作新篇章
大连日报今日新闻： 8 大连市对口支援（帮扶）地区农特产品展销会落幕
大连日报今日新闻： 9 抢抓共建“一带一路”机遇 深度融入全球经济
大连日报今日新闻： 10 我市2名运动员1名教练员将出征杭州亚残运会
大连日报今日新闻： 11 每人奖励12万元！我市新选树20名“大连工匠”
大连日报今日新闻： 12 大连天气
爬取结束！！

3. 难点与亮点

这段代码的亮点在于：

1. ****清晰的注释和文档****：代码附带有详细的注释，有助于理解每个部分的功能和目的。
2. ****良好的模块化****：代码使用模块化的方式组织，从而提高了可读性和可维护性。
3. ****合理的异常处理****：脚本包含了异常处理机制，能够捕获可能发生的异常情况，提高了代码的健壮性。
4. ****使用外部库****：充分利用了 `Requests` 和 `BeautifulSoup` 这两个强大的外部库，简化了网络请求和 `HTML` 解析的过程。
5. ****动态构建 URL****：代码使用当前日期动态构建目标 `URL`，使其更具通用性，不受日期变化的影响。

而难点可能在于：

1. ****页面结构变化的适应性****：如果大连日报网站的页面结构发生变化，可能需要及时更新代码以适应新的结构。
2. ****网络请求错误处理的完善性****：虽然有基本的错误处理，但可能需要更全面的处理机制，覆盖更多可能的网络问题。
3. ****编码处理的准确性****：自动检测网页编码的方法可能不总是准确，对于一些特殊情况可能需要手动指定编码。

三：总结体会

编写这段代码的主要目的是实现简单的网络爬虫，从大连日报的网页上抓取今日新闻标题并输出到控制台。以下是编写这些代码时的总结与体会：

****总结**：**

1. ****目标明确****：在编写代码之前，明确了要实现的目标，即从指定网页上获取新闻标题，这有助于编写代码的逻辑。
2. ****使用第三方库****：利用 `Requests` 和 `BeautifulSoup` 库，简化了 HTTP 请求和 HTML 解析过程，提高了代码的效率和可读性。
3. ****动态构建 URL****：代码动态构建目标 URL，基于当前日期，使其更具通用性，不需要手动更改 URL。
4. ****错误处理****：虽然异常处理部分相对简单，但它考虑到了可能出现的网络请求错误，这是一种良好的实践。
5. ****注释和命名****：代码中包含注释，说明了各个部分的作用，同时变量和函数命名也较为清晰，有助于代码的可维护性。

****体会**：**

- 学习如何创建一个简单的网络爬虫。
- 熟悉和掌握第三方库，如 `Requests` 和 `BeautifulSoup`，是编写网络爬虫的重要一步。引入了外部库 `Requests` 和 `BeautifulSoup`，减少了手动处理 HTTP 请求和 HTML 解析的工作。
- 网络爬虫开发需要考虑到网站结构变化和可能的异常情况，因此代码可以进一步改进，以增强稳定性和适应性。
- 动态构建 URL 根据当前日期，使代码更具通用性，不需要手动更改 URL。
- 错误处理部分，虽然简单，但在处理常见网络请求错误方面是有帮助的。
- 代码还可以进一步改进，以适应潜在的变化和错误情况，例如，考虑如何处理反爬虫机制、网络超时等。

总的来说，这是一个简单的网络爬虫脚本。不过，对于生产环境或更严格的应用，可能需要更多的稳定性和异常处理机制。