

学号： 2106410103



沈阳建筑大学

大数据技术基础 综合设计报告

2023 年秋季学期

学 院： 计算机科学与工程学院

专业班级： 计算机 2101 班

姓 名： 方廷伟

一.题目名称:

Python 开发爬虫爬取红豆论坛的数据软件与实现

二、分析与设计:

1、需求分析:

1.数据采集和分析: 爬虫可以用于采集互联网上的大量数据, 如新闻、社交媒体内容、商品信息等。这些数据可以用于市场调研、舆情分析、数据挖掘等领域, 帮助做出有针对性的决策。

2.网站更新监测: 爬虫可以周期性地监测和抓取目标网站的变化, 例如新闻网站、论坛、博客等。这有助于及时了解网站内容更新、关注竞争对手动态或监测用户评论和反馈等。

3.自动化操作和任务: 通过爬虫可以进行一些自动化操作和任务, 如自动填写表单、自动提交数据、自动发送邮件等。这有助于提高工作效率和降低重复操作的工作负担。

4.需要注意的是, 使用爬虫时应遵守法律法规和目标网站的规则, 尊重隐私和版权。并且, 在进行爬取操作时需关注网络安全和数据保护, 确保数据使用的合法性和安全性。

2、功能设计。

1.在获取的 url 地址中使用%d 占位符, 为后面爬取多页数据做准备

2. `print(res.status_code)` 前期可以打印一下状态码, 看请求成不成功。

3. `time.sleep(1)`, 一秒钟爬取一次, 保守起见, 不要给别人服务器造成太大压力, 如果一直频繁请求你可能会被拉入黑名单。

4. 是 GBK, 但是大部分的网站编码格式都是 utf-8

`p = open('./hongdou.csv','w',encoding='utf-8')` 想要保存成 txt 格式都可 以略, 为什么这里编码是 utf-8, 这是反复测试的结果, 不然保存会乱码, 就是那么奇怪。

1. `5.s_url=url%(i+1)`如果像是翻一页+20, 括号里也可以写成*(i*20)*, 但是 range 里面就需要相应的改变了, 比如 $2 \times 20 = 40$, $3 \times 20 = 60 \dots$

三、系统实现

1、程序实现。

主要代码:

```
# -*- coding: utf-8 -*-
```

```
"""
```

Created on Wed Oct 18 16:33:20 2023

```
@author: 86157
```

```
"""
```

```
import requests
import time
from lxml import etree
#url
url='http://hongdou.gxnews.com.cn/viewforum-21-%d.html'
#请求头
headers={
    'User-Agent': 'Mozilla/5.0 (Windows NT 10.0; WOW64)
AppleWebKit/537.36 (KHTML, like Gecko) Chrome/83.0.4103.61
Safari/537.36'
}
if __name__ == '__main__':
    #写入
    #fp = open('./hongdou.csv','w',encoding='utf-8')
    #获取多页数据
    for i in range(20):
        s_url=url%(i+1)
        res = requests.get(s_url,headers=headers) #发起请求
        res.encoding='gbk' #设置编码格式
        text = res.text
        html = etree.HTML(text)
        items = html.xpath('//div[@class="threadbit1"]')
        # print(res.status_code)
        for item in items:
            title=item.xpath('./div[@class="thread-row
openTitle"]/a/font/text()'),

yeshu=item.xpath('./span[@class="threadpages"]/text()'),

author=item.xpath('./div[@style="float:right;width:80px;line-height:16p
x;"]/a[1]/text()'),
```

```

fa_time =
item.xpath('..//div[@style="float:right;width:80px;line-height:16px;"]/a[2]
/text()/),

lend_author=item.xpath('..//div[@style="float:right;width:100px;line-height:16px;"]/a[1]/text()/),
lend_time =
item.xpath('..//div[@style="float:right;width:100px;line-height:16px;"]/a[2]/text()/);

print(title,yeshu,author,fa_time,lend_author,lend_time)

#fp.write('%s\t%s\t%s\t%s\t%s\t%s\n'%(title,yeshu,author,fa_time,lend
_author,lend_time))
# print(title[i])
time.sleep(1)
print('第%d 页爬取成功'%(i+1))

# fp.close()

```

2、运行与测试。

网页中打开

【原创】【我想对你说谢谢】征集你身边的“凡人善举”，说出你想感谢的那个ta  +10	2023-10-17	13/120	2023-10-18 14:36
江南区：向日葵花海美如画  +12	2023-10-17	13/829	心仪广西 2023-10-18 15:53
【原创】杭州亚运会现场抓拍  +10 [2 页]	2023-10-10	27/726	绿城寻梦 2023-10-18 15:40
【原创】在良凤江森林公园拍天宁寺  +12 [3 页]	2023-10-16	56/762	心仪广西 2023-10-18 15:30
【原创】拍于泰山顶上的“抢”子对联  [2 页]	2023-05-13	23/681	逗狗捉妖专业户 2023-10-18 15:11
那盏光，划破苍穹穿越时空——来自“中国革命摇篮”井冈山的精神之光 [10 页]	2021-04-07	188/1719	逗狗捉妖专业户 2023-10-18 15:10
【原创】《秋江夜》  New!	2023-10-18	0/3	亲缘阁 2023-10-18 15:06
广西首届养生美食节暨桂菜“三名”评选活动启动	2023-10-17	1/21	凝炼 2023-10-18 14:35
抽丝剥茧情线追踪，广西刑事技术精英同场竞技	2023-10-17	1/14	凝炼 2023-10-18 14:34
打造平陆运河民政服务设施示范建设，广西将这样做	2023-10-17	1/12	凝炼 2023-10-18 14:33
监督故事 追回多发的种粮补贴	2023-10-17	1/15	凝炼 2023-10-18 14:32
中国—东盟传统医药健康旅游国际论坛在巴马举办  New!	2023-10-17	1/11	凝炼 2023-10-18 14:32
“环广西”第五赛段在柳发车，“最美赛道”上演“速度与激情”	2023-10-17	6/116	依依 2023-10-18 13:54
【原创】《画飞花》  New!	2023-10-18	0/7	亲缘阁 2023-10-18 11:57
【原创】艺术欣赏  New!	2023-10-17	3/37	豆豆爱痘痘 2023-10-18 11:23

保存为 houdou.csv 文件:

[illegible]

控制台输出

```
In [45]: runfile('D:/桌面/python/未命名3.py', wdir='D:/桌面/python')
(['江南区: 向日葵花海美如画'], ([],) (['没选择'],) (['2023-10-17'],) (['心仪广西'],)
['2023-10-18 15:53'])
(['杭州亚运会现场抓拍 ——'],) (['[ 2 页]'],) (['绿城寻梦'],) (['2023-10-10'],) (['绿城
梦'],) ['2023-10-18 15:40']
(['在良凤江森林公园拍天宁寺'],) (['[ 3 页]'],) (['凝炼'],) (['2023-10-16'],) (['心仪广
西'],) ['2023-10-18 15:30']
(['拍于泰山顶上的“抢”字对联'],) (['[ 2 页]'],) (['锂曦月'],) (['2023-05-13'],) (['逗狗
妖专业户'],) ['2023-10-18 15:11']
(['那道光, 划破苍穹穿越时空——来自“中国革命摇篮”井冈山的精神之光'],) (['[ 10 页]'],) (['
逗狗捉妖专业户'],) (['2021-04-07'],) (['逗狗捉妖专业户'],) ['2023-10-18 15:10']
(['《桃花源记》'],) (['[ 1 页]'],) (['《桃花源记》'],) (['2023-04-03'],) (['《桃花源记》'],) (['2023-10-18 15:10'])
```

3、难点和亮点。
获取 URL 和请求头



四、总结体会

1. 深入理解网络爬虫：通过编写爬虫，我对网络爬虫的工作原理有了更深入的理解。我学会了如何发送 HTTP 请求，解析网页内容，提取所需信息等。这让我对互联网的运作有了更清晰的认识。
2. 遵守爬虫道德和法律规定：在编写爬虫的过程中，我意识到了合法和道德使用爬虫的重要性。我学会了尊重网站的爬虫规则，遵守 Robots 协议，避免对目标网站造成过大的负担，同时也要注意遵守相关的法律法规，保护个人隐私和知识产权。

总的来说，编写爬虫是一项有挑战性但也很有趣的任务。通过编写爬虫，我不仅学到了很多有关网络爬虫的知识和技术，还培养了问题解决和数据处理的能力。同时，我也更加明白了爬虫开发中的合法和道德的重要性，以及持续学习和改进的必要性。