

学号： 2106410101



沈阳建筑大学

大数据技术基础 综合设计报告

2023 年秋季学期

学 院： 计算机科学与工程学院

专业班级： 计算机 2101 班

姓 名： 马胜涛

正文格式：中文宋体、英文数字 Times New Roman、小四、单倍行距。

一、题目名称：Python 开发微博热搜前 50 爬虫软件设计与实现

二、分析与设计：

1、需求分析。

2、功能设计。

三、系统实现

1、程序实现。

2、运行与测试。

3、难点和亮点。

四、总结体会

结课考试后交报告电子版、打印版(总字数不少于 1000 字,建议双面打印),可以有少量代码,但不能连续 2 页或超过 2 页都是代码。可以小组合作完成,但报告必须一人一份,且在报告中说明个人独立完成的部分。小组人数不超过 2 人。

电子版发 email 至 9455@sohu.com。

一、题目名称

Python 开发微博热搜榜前 50 爬虫软件设计与实现。

二、分析与设计：

1、需求分析

本次爬虫目的是要获取微博热搜榜前 50 具体榜单，用户可以清晰了解到微博热搜榜 top50；该爬虫能自动生成一个 txt 文本文件，并将热搜时事显示在文档中。

2、功能设计

通过爬虫能够获取微博热搜榜前 50 具体榜单，首先进行了微博网址设计：<https://tophub.today/n/KqndgxeL19>；然后加上了 headers 用来告诉网站这是一个通过浏览器进行的访问；最后获取微博前 50 热搜排名，热搜实时名称以及浏览人数的具体数据。

三、系统实现

1、程序实现。

```
import requests
from lxml import etree

url = "https://tophub.today/n/KqndgxeL19"
headers = {
    'user-agent': 'Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/109.0.0.0 Safari/537.36 Edg/109.0.1518.69'
}
res=requests.get(
    url = url,
    headers = headers
)


html = etree.HTML(res.text)
trs =
html.xpath('/html/body/div[1]/div[2]/div[2]/div[1]/div[2]/div/div[1]/table/tbody/tr')
```

```
def getfirsttext(list):
    """
    返回列表中第一个元素
    :return:
    """
    try:
        return list[0].strip()
    except:
        return ""
```

```
file = open("微博热搜 top50.txt",mode = "w", encoding = "utf-8")
for tr in trs:
    id = getfirsttext(tr.xpath('./td[1]/text()'))
    title = getfirsttext(tr.xpath('./td[2]/a/text()'))
    play = getfirsttext(tr.xpath('./td[3]/text()'))
    print(id, title, play)
    file.write(str(id) + " " + title + "," + str(play) + "\n")
file.close()
```

2、运行与测试。

运行时间为 2023 年 10 月 16 日 20 点 33 分。



```
Python 3.11.4 | packaged by Anaconda, Inc. | (main, Jul 5 2023, 13:38:37) [MSC v.1916 64 bit (AMD64)]
Type "copyright", "credits" or "license()" for more information.

IPython 8.12.0 -- An enhanced Interactive Python.

In [1]: runfile('D:/2023Autumn/大数据技术与应用/大作业/微博热搜榜前50爬虫.py', wdir='D:/2023Autumn/大数据技术与应用/大作业')
1. 一带一路十年之约
2. 街道办已动员数百人寻找肇事烈犬 166.4万
3. 朱一龙 北大 电影 1298621
4. 杭州亚残运村今天开村了 108.6万
5. Swisse热巴秦岚周也同台
6. 狗主人责任 105.3万
7. 小胖 努力三年只为你和你顶峰相见 97.1万
8. 母亲讲述女童被大型犬撕咬致肾破裂 73.8万
9. 中国政府向巴勒斯坦提供紧急人道主义援助 66.9万
10. 胖胖的李 38.8万
11. 死掉的大闸蟹有多毒 34.9万
12. 国足vs乌兹别克斯坦 33.6万
13. 拉布拉多 33.5万
14. 两大型犬撕咬2岁半女童致严重受伤 33.3万
15. 刘诗诗谢娜同框看秀 33.0万
16. 赵今麦在穿 32.6万
17. 麻黄拿铁 32.5万
18. 被田耕纪气死 剧集 301005
19. 塞尔维亚总统武契奇抵华 29.4万
20. 白鹿带闺蜜看五月天演唱会 演出 272767
21. 博主100元吃遍东北早市被指造假 25.2万
22. 莲花楼台词中的治愈感 剧集 244943
23. MiuMiu钻石内裤 24.4万
24. 钟楚曦曾在七夕被分手 综艺 244302
25. 林俊杰戚薇 演出 243651
26. 我们四个把日子过好比什么都强 23.6万
27. 爸妈一次性给了四年的生活费 23.5万
28. 明天秋裤备好 22.8万
29. 特斯拉车主高速多次别车被刑拘 20.5万
30. 徐植珍与BBD公司签约 20.1万
31. 韩火火大秀集齐顶流综艺 19.6万
32. 蔡文静姜拉德穿搭 19.5万
33. 孟子义问范丞丞是不是创造营第一 综艺 194760
34. 赵丽颖工作室换头像 19.3万
35. 被狗咬伤女童生命体征平稳 18.5万
36. 自建房造的丑 关我入住后什么事 18.2万
37. 迪丽热巴秦岚周也美女贴贴 17.8万
```

```
微博热搜top50.txt
文件 编辑 查看
1. 一带一路十年之约, 166.4万
2. 街道办已动员数百人寻找肇事烈犬, 1298621
3. 朱一龙 北大, 电影 1298621
4. 杭州亚残运会今天开村了, 108.6万
5. Swisse热巴赛凤凰也同台, 105.3万
6. 狗主人责任, 97.1万
7. 小胖 努力三年只为和你顶峰相见, 73.8万
8. 母亲讲述女童被大型犬撕咬致肾破裂, 66.9万
9. 中国政府向巴勒斯坦提供紧急人道主义援助, 38.8万
10. 胖胖的李, 34.9万
11. 死猪的大闸蟹有多毒, 33.6万
12. 国足vs乌兹别克斯坦, 33.5万
13. 拉布拉多, 33.3万
14. 两大型犬撕咬2岁半女童致严重受伤, 33.0万
15. 刘诗诗谢娜同框看秀, 32.6万
16. 赵今麦在穿, 301005
17. 麻杏拿铁, 29.4万
18. 被田耕纪气死, 剧集 272767
19. 塞尔维亚总统武契奇抵华, 25.2万
20. 白鹿带闺蜜看五月天演唱会, 演出 244943
21. 博主100元吃遍东北早市被指造假, 24.4万
22. 莲花楼台词中的治愈感, 剧集 244302
23. Miumiu钻石内裤, 243651
24. 钟楚曦曾在七夕被分手, 综艺 23.6万
25. 林俊杰威阳, 演出 23.5万
26. 我们四个把日子过好比什么都强, 23.5万
27. 爸妈一次性给了四年的生活费, 22.8万
28. 明天秋裤备好, 20.5万
29. 特斯拉车主高速多次别车被刑拘, 20.1万
30. 徐穗珍与BRD公司签约, 19.6万
31. 韩火火大秀集齐顶流综艺, 19.5万
32. 蔡文静美拉德穿搭, 19.3万
33. 孟子义向范丞丞是不是创造营第一, 综艺 18.2万
34. 赵丽颖工作室换头像, 17.8万
35. 被狗咬伤女童生命体征平稳, 166136
36. 自建房造的丑 关我入住后什么事, 16.0万
37. 迪丽热巴赛凤凰也美女贴贴, 15.8万
38. 仲溪午男狐狸, 剧集 15.4万
39. 倩久唯爱AG, 15.4万
40. 街道办回应女童被大黑狗撕咬, 15.4万
41. 华为 谢霆锋, 15.4万
42. 尊重式分手, 15.3万
43. 这才是面试官爱听的离职原因, 14.5万
44. 外交部建议在以中国公民尽快回国, 14.4万
45. 今天是A股6124点16周年, 14.4万
46. 迪丽热巴赛金长裙梦回乔晶晶, 14.4万
47. 关智斌找徐良为容祖儿写歌, 综艺 14.2万
48. 一起开启丝路奇旅, 14.2万
49. 英雄联盟电竞世界杯总决赛
行 3, 列 21 | 100% | Windows (CRLF) | UTF-8
```

3、难点和亮点。

这段代码用于爬取微博热搜榜前 50 的信息并保存到文本文件中。以下是对这段代码的难点和亮点：

难点：

- 1. XPath 解析：使用 XPath 解析 HTML 页面是一项具有挑战性的任务，因为需要准确地定位和提取所需的信息。这段代码需要通过 XPath 定位表格中的每一行并提取数据。
- 2. 异常处理：异常处理是良好的编程实践，但它增加了代码的复杂性。

亮点：

- 1. 良好的注释：代码中包含了一些注释，帮助其他开发人员理解代码的逻辑和功能。
- 2. 模块化：代码将一些操作封装在函数中，例如 getfirsttext 函数用于获取列表中的第一个元素。这提高了代码的模块化和可维护性。

四、总结体会

通过本次爬虫设计，以下是我的一些总结体会：

1. 了解爬虫基础知识：在开始设计爬虫之前，需要先了解爬虫的基础知识，包括爬虫的定义、原理、分类、流程等等。只有了解这些基础知识，才能更好地设计爬虫。
2. 确定爬取目标：设计一个好的爬虫之前，需要明确爬取目标。对于不同的场合，爬取目标也是不同的。比如，爬取网站内容和爬取手机应用数据是不同的。
3. 设计爬取策略：在确定了爬取目标之后，需要设计爬取策略。这包括选择合适的编程语言、确定爬虫结构和设计爬虫算法等。
4. 爬取数据分析和清洗：在爬虫爬取了大量的数据之后，需要对爬取到的数据进行分析 and 清洗，目的是将爬取到的数据转换成有用的格式。
5. 存储数据：需要将爬取到的数据存储下来，以备后续使用。数据存储可以采用关系数据库或非关系数据库等方式。

以上总结体会只是简单的介绍，爬虫的设计还有很多需要注意的地方，需要在实际操作中不断摸索和实践。通过本次 Python 开发微博热搜榜前 50 爬虫软件设计与实现，我学会了如何发起 HTTP 请求、使用 XPath 解析 HTML、处理异常、写入文件等技能。这对于日常的数据采集任务非常有用。网络爬虫能够获取大量的数据，但获取到的数据通常需要一定的整理和处理才能变得有用。编写网络爬虫代码时，需要遵守网站的使用政策和法律法规，以确保合法和伦理的操作。保存数据到文件是一个常见的任务，这段代码演示了如何将数据写入文本文件中，以备后续分析或分享。在编写爬虫代码时，需要不断学习和改进，以应对不同网站和数据源的挑战。