

学号： 2006410117



沈阳建筑大学

大数据技术基础 综合设计报告

2023 年春季学期

学 院： 计算机科学与工程学院

专业班级： 计算机 2101 班

姓 名： 杨金娜

正文格式：中文宋体、英文数字 Times New Roman、小四、单倍行距。

一、题目名称：Python 开发链家售房信息爬虫软件设计与实现

二、分析与设计：

1、需求分析：

我做的是爬取链家上海市静安区售房信息的爬虫代码，该网站网址为：

<https://sh.lianjia.com/ershoufang/jingan/pg{page}/>

从该网站中我们可以爬取的内容有：标题，地址，户型，面积，朝向，装修，楼层，年代，关注及发布，其它，总价，单价，详情等相关信息。在我的爬虫程序运行结果中均体现出来。

2、功能设计：

首先导入美丽汤库、URL、XLWT 和正则表达式，用来获取、传输和保存文件。

然后再声明四个函数：main 函数、爬取数据函数、访问网页函数、保存函数

最后再声明两个全局变量电影名称和电影相关信息分别在四个函数中调用。

三、系统实现

发送请求，模拟浏览器对于 url 地址发送请求

获取数据，获取网页数据内容 --> 请求那个链接地址，返回服务器响应数据

解析数据，提取我们需要的数据内容

保存数据，保存本地文件

1、程序实现：

声明一个访问网页函数：askURL(url)，并在其中创建一个浏览器头部信息调用 URL 访问指定的网页。

```
time.sleep(3)

print(f'===== 正在爬取第 {page} 页数据内容
=====')

url = f'https://sh.lianjia.com/ershoufang/jingan/pg{page}/'

headers = {
```

```
'User-Agent': 'Mozilla/5.0 (Windows NT 10.0; Win64; x64)
AppleWebKit/537.36 (KHTML, like Gecko) Chrome/98.0.4758.82
Safari/537.36'}
```

```
response = requests.get(url=url, headers=headers)
```

获取所有房源所在标签

```
selector = parsel.Selector(response.text)
```

```
divs = selector.css('div.info.clear')
```

选用 css 选择器：根据标签属性提取数据内容，例如标题的替换，因为有一些图片的标题，其中会包含特殊字符，在创建文件的时候特殊字符是不能命名的，所以需要使用正则把有可能出现的特殊字符替换掉。

for 循环遍历

```
title = div.css('.title a::text').get()
```

```
area_list = div.css('.positionInfo a::text').getall()
```

```
area = '-'.join(area_list)
```

```
house_info = div.css('.houseInfo::text').get().split(' |')
```

```
house_type = house_info[0]
```

```
house_area = house_info[1]
```

```
house_face = house_info[2]
```

```
decoration = house_info[3]
```

```
floor = house_info[4]
```

```
years = house_info[5]
```

```
follow_info = div.css('.followInfo::text').get().replace(' / ',
',')
```

```
tag_list = div.css('.tag span::text').getall()
```

```

tag = '|'.join(tag_list)

totalprice = div.css('.totalPrice span::text').get() + '万'

unitprice = div.css('.unitPrice span::text').get().replace('单价', '')

href = div.css('.title a::attr(href)').get()

dit = {
    '标题': title,
    '地址': area,
    '户型': house_type,
    '面积': house_area,
    '朝向': house_face,
    '装修': decoration,
    '楼层': floor,
    '年代': years,
    '关注及发布': follow_info,
    '其它': tag,
    '总价': totalprice,
    '单价': unitprice,
    '详情': href,
}

```

保存数据

通过 CSV 将爬取的信息写入到 excel 表格中并保存。

```

csv_write.writerow(dit)

print(title, area, house_type, house_area, house_face, decoration, floor,
years, follow_info, tag, totalprice,
      unitprice, href, sep='|')


```

```
print("爬取完毕！")
```

2、运行与测试：

通过设计我们需要用程序爬取网站上前五十个信息，并将其导入 excel 表格中并保存。

通过测试我们成功将网页信息存入 excel 表格中，且程序未显示报错，如下图所示可见：



```
In [2]: runfile('C:/Users/86187/Desktop/杨金娜大数据课设+课后作业/作业五静安区售房信息.py', wdir='C:/Users/86187/Desktop/杨金娜大数据课设+课后作业')
=====正在爬取第1页数据内容=====
高区明亮大三房 税费少 看房方便 价格可以沟通|华纺小区 -曹家渡|3室1厅 | 64.81平米
| 南 | 简装 | 6层 | 1986年建 |6人关注,7天以前发布|近地铁|VR房源|房本满五年|
475万|73,292元/平|https://sh.lianjia.com/ershoufang/107108218869.html
永和二村,中楼层三室户,一梯两户,看房随时!|永和二村 -永和|3室1厅 | 70.01平米
| 南 北 | 毛坯 | 中楼层(共6层) | 1995年建 |0人关注,9天以前发布|VR看装修|房本
满五年|随时看房|458万|65,420元/平|https://sh.lianjia.com/ershoufang/
107108201197.html
满五仅一税少 2梯2户高得房 楼栋位好南北带景观随时看|静安河滨花园 -江宁路|3室2厅
| 131.21平米 | 南 西南 | 精装 | 中楼层(共25层) | 2003年建 |16人关注,9天以前发
布|近地铁|VR房源|房本满五年|随时看房|1300万|99,078元/平|https://
sh.lianjia.com/ershoufang/107108208921.html
高楼层+好视野+好采光+好价格+好装修+带车位|静安府西区 -大宁|3室2厅 | 121.08
平米 | 南 | 精装 | 高楼层(共33层) | 板楼|7人关注,19天以前发布|VR看装修|房本满
两年|1579万|130,410元/平|https://sh.lianjia.com/ershoufang/
107108147026.html
```


"utf-8-sig"读取带有 BOM 的"utf-8 文件时"会把 BOM 单独处理,与文本内容隔离开,也是我们期望的结果。

四、总结体会

本次课设所有内容基本我一人完成,在安装 xlwt 类库时,我遇到了各种各样的问题,通过 CSDN 和老师的帮助,最终成功解决了这个问题。通过大数据技术基础综合程序设计,我掌握了比较多的 python 知识,我们通过查找课本以及翻阅网站,了解 python 程序如何进行需求分析、功能设计和程序实现,将其一一实现。并对正则表达式和各类库的运行方式有了更进一步的理解。但是我们的程序依然还有很多不足,比如爬取网页信息时,获取页面信息格式颇为固定,未达到理想效果,希望在以后的学习中我希望可以通过数据清洗来解决这个问题。