

学号： 2106410119



沈阳建筑大学

大数据技术基础 综合设计报告

2023 年秋季学期

学 院： 计算机科学与工程学院

专业班级： 计算机 2101 班

姓 名： 陈芷涵

一、题目名称：基于机器学习的温度预测：随机森林回归

二、分析与设计：

1、需求分析

1. 数据读取：程序需要能够读取温度数据的 CSV 文件，并将数据加载到内存中以供后续处理和建模使用。
2. 数据预处理：程序需要对原始数据进行预处理，包括处理时间数据、特征编码和数据集划分等。
3. 建模和训练：程序需要使用随机森林回归模型对温度的最大值进行建模和训练。这包括设置模型参数、拟合训练数据并生成模型。
4. 预测和评估：程序需要使用训练好的模型对测试数据进行预测，并计算预测结果与实际标签之间的误差指标，如绝对误差和平均绝对百分比误差。
5. 特征重要性分析：程序需要分析随机森林模型中各个特征的重要性，并输出特征重要性排序。
6. 可视化分析：程序需要绘制实际值和预测值的曲线图，以使用户可以直观地观察预测结果和原始数据之间的关系。

2、功能设计

1. 数据加载功能：实现从 CSV 文件中读取温度数据的功能，并将数据存储在适当的数据结构中，如 Pandas DataFrame。
2. 数据预处理功能：包括处理时间数据、特征编码和数据集划分等步骤，确保数据可以被模型使用。
3. 模型训练功能：实现使用随机森林回归模型进行训练的功能，包括设置模型参数、拟合训练数据并生成训练好的模型。
4. 预测功能：使用训练好的模型对测试数据进行预测，得出温度的最大值预测结果。
5. 评估功能：计算预测结果与实际标签之间的误差指标，如绝对误差和平均绝对百分比误差。
6. 特征重要性分析功能：分析随机森林模型中各个特征的重要性，并输出特征重要性排序。
7. 可视化功能：绘制实际值和预测值的曲线图，以使用户可以直观地观察预测结果和原始数据之间的关系。
8. 用户界面：可选择性地实现一个用户界面，以使用户可以通过界面交互来执行程序的各项功能。

三、系统实现

1、程序实现


```
# 数据读取
import pandas as pd
from sklearn import metrics
features = pd.read_csv('temps.csv')
features.head(5)
# 处理时间数据
import datetime
years = features['year']
months = features['month']
days = features['day']
# 准备画图
import matplotlib.pyplot as plt
plt.style.use('fivethirtyeight')
fig, ((ax1, ax2), (ax3, ax4)) = plt.subplots(nrows=2, ncols=2, figsize = (10,10))
fig.autofmt_xdate(rotation = 45)
# 导入算法
from sklearn.ensemble import RandomForestRegressor
# 建模
rf = RandomForestRegressor(n_estimators= 1000, random_state=42)
# 训练
rf.fit(train_features, train_labels)
# 预测结果
predictions = rf.predict(test_features)
# 得到特征重要性
importances = list(rf.feature_importances_)
feature_importances = [(feature, round(importance, 2)) for feature, importance
in zip(feature_list, importances)]
feature_importances = sorted(feature_importances, key = lambda x: x[1],
reverse = True)
[print('Variable: {:20} Importance: {}'.format(*pair)) for pair in
feature_importances]
x_values = list(range(len(importances)))
# 绘图
plt.bar(x_values, importances, orientation = 'vertical')
plt.xticks(x_values, feature_list, rotation='vertical')
plt.ylabel('Importance'); plt.xlabel('Variable'); plt.title('Variable Importances');
```

```


# 选择最重要的那两个特征来试一试
rf_most_important = RandomForestRegressor(n_estimators= 1000,
random_state=42)
# 拿到这俩特征
important_indices = [feature_list.index('temp_1'), feature_list.index('average')]
train_important = train_features[:, important_indices]
test_important = test_features[:, important_indices]
# 重新训练模型
rf_most_important.fit(train_important, train_labels)
# 预测结果
predictions = rf_most_important.predict(test_important)
errors = abs(predictions - test_labels)
# 评估结果
mape = np.mean(100 * (errors / test_labels))
print('mape:', mape)
# 真实值
plt.plot(true_data['date'], true_data['actual'], 'b-', label = 'actual')
# 预测值
plt.plot(predictions_data['date'], predictions_data['prediction'], 'ro', label =
'prediction')
plt.xticks(rotation = '60');
plt.legend()

```


2、运行与测试。



图一 最高温度相关



图二 引用变量的重要性



图三 实际值和预测值

3、难点和亮点

(1) 难点:

1. 数据预处理: 数据预处理是一个关键的步骤, 需要处理时间数据、特征编码等。处理时间数据可能涉及到日期解析、时间序列处理和特征提取等复杂操作。此外, 特征编码可能需要处理类别型特征和独热编码等。
2. 模型参数调优: 随机森林模型有多个参数需要调优, 如决策树数量、树的深度等。选择合适的参数组合可以提高模型的性能, 但需要经过多次实验和评估。
3. 特征工程: 根据实际问题, 选择合适的特征对模型性能至关重要。需要进行特征选择、特征变换和特征组合等工程化处理, 以提升模型的预测能力。
4. 模型解释性: 随机森林模型的预测结果可能难以解释, 特别是当特征较多时。对于一些特定的预测结果, 难以了解模型是如何得出该结果的。

（2）亮点：

1. 机器学习建模：程序利用机器学习技术中的随机森林回归算法，能够对温度的最大值进行预测。通过学习历史温度数据的模式和趋势，模型可以提供有用的预测结果。
2. 特征重要性分析：程序能够分析随机森林模型中各个特征的重要性，帮助用户了解哪些特征对预测结果的影响最大。这对于进一步理解温度变化的因素和特征选择具有指导意义。
3. 可视化分析：通过绘制实际值和预测值的曲线图，用户可以直观地观察预测结果和原始数据之间的关系。这样的可视化分析有助于用户更好地理解模型的性能和预测结果的准确性。
4. 可扩展性：程序的设计允许用户根据实际需求进行调整和扩展。用户可以根据需要进行参数调优、特征工程和模型选择等，以获取更好的预测性能。

四、总结体会

这个程序结合了机器学习建模和温度预测领域的知识，通过随机森林回归算法对温度的最大值进行预测。通过对历史温度数据的学习，程序能够提供有用的预测结果，并通过特征重要性分析帮助用户了解影响预测结果的关键特征。

这个程序展示了机器学习在温度预测中的应用，并提供了对温度最大值的预测结果和特征分析。它为用户提供了一种可靠的工具，以便在温度相关的应用场景中做出更准确的预测和决策。

这个课设让我学习和应用了随机森林回归算法的原理，以及数据预处理、特征工程和模型训练等内容。提高了我的数据处理和预处理能力：项目中需要对温度数据进行处理和预处理。这很好的锻炼我处理实际数据的能力，包括数据加载、数据清洗、特征提取和特征编码等。我学会了使用 Python 的数据处理库（如 Pandas）和技术来处理 and 准备数据。通过该项目，我学会了如何调整模型的参数以获得更好的性能。我不断探索不同的参数组合，并使用评估指标（如绝对误差和平均绝对百分比误差）来评估模型的准确性。这培养了我的实验设计和模型调优的能力。

在项目中，我通过绘制曲线图和分析特征重要性来进行可视化分析。这帮助我更好地理解数据和模型预测结果之间的关系，以及哪些特征对预测结果的影响最大。这个项目需要我在实践中自主学习和解决问题，我遇到各种挑战，如数据质量问题、模型性能改进等。通过解决这些问题，很好的培养自主学习和解决问题的能力。

这份 Python 课设对我来说是一个很好的学习机会，它帮助我深入理解机器学习建模的过程，并为我提供了锻炼数据处理、参数调优、可视化分析和自主学习能力的机会。通过完成这份课设，我对专业知识有了更好的掌握，提升了我在数据科学和机器学习领域的技能和竞争力。