

学号： 2106410120



沈阳建筑大学

大数据技术基础 综合设计报告

2023 年秋季学期

学 院： 计算机科学与工程学院

专业班级： 计算机 2101 班

姓 名： 魏露林

正文格式：中文宋体、英文数字 Times New Roman、小四、单倍行距。

一、题目名称：Python 开发 XXX 软件设计与实现

二、分析与设计：

1、需求分析。

读者通常需要在众多可选的图书中进行选择。他们希望了解不同书籍的特点、评价和推荐指数，以帮助他们选择适合自己兴趣和需求的图书。比如读者可能对特定领域、作者或出版社感兴趣，他们需要深入了解相关图书的情况，包括书籍数量、评价、价格等。或者希望找到价格合理的图书，可以从折扣和促销中受益。他们需要比较售价和原价，以找到最划算的购买选项。

项目通过从当当网等网站获取大量的图书信息，包括书名、评论数量、推荐指数、作者、出版日期、出版社、售价、原价、折扣等。这些信息可以帮助读者了解图书的特点和价格情况。

该项目，为他们提供了一个有用的工具，以帮助他们选择适合自己兴趣和需求的图书，了解图书的评价和价格情况，以及寻找优惠购买选项。这有助于读者更好地参与图书市场，找到他们喜欢的阅读材料。该程序的主要目标是爬取当当网上的图书信息，并进行数据可视化分析，以便更好地了解图书市场的情况。

2. 功能设计

1. 数据爬取功能

实现数据爬取功能，能够向当当网的图书排行榜页面发送 HTTP 请求，获取多页的图书信息。

提取所需的图书信息，包括书名、评论数量、推荐指数、作者、出版日期、出版社、售价、原价、折扣和详情页链接。

逐页爬取并迭代数据，将数据写入 CSV 文件。

2. 数据分析功能

统计不同推荐指数的数量，用于生成推荐占比分布的饼图。

统计各个出版社的书籍数量，用于生成各个出版社书籍数量的柱状图。

3. 数据可视化功能

使用`pyecharts`库创建推荐占比分布的饼图，显示不同推荐指数的分布情况。

使用`pyecharts`库创建各个出版社书籍数量的柱状图，展示各出版社的书籍数量情况。

将生成的图表以 HTML 文件的形式保存，以便查看和分享。

三、系统实现

1、程序实现。

项目导入包：

```
import requests
```

```

import parsel
import csv
import pandas as pd
from pandas import DataFrame
from pyecharts.charts import *
from pyecharts.globals import ThemeType#设定主题
from pyecharts.commons.utils import JsCode
import pyecharts.options as opts
from pyecharts import options as opts
from pyecharts.charts import Pie
2. 爬虫实现
f = open('data.csv',mode='w',encoding='utf-8',newline='')
csv_writer=csv.DictWriter(f, fieldnames=[
    '标题',
    '评论',
    '推荐',
    '作者',
    '出版日期',
    '出版社',
    '售价',
    '折扣',
    '原价',
    '详情页',
])
csv_writer.writeheader()
for page in range(1,26):
url=
http://bang.dangdang.com/books/bestsellers/01.00.00.00.00.00-recent7-0-0-1-{page}
    response = requests.get(url)
    print(response)
3. 数据分析
#推荐占比分布
tui_number = df['推荐'].value_counts().tolist()      #获取数量
tui_type = df['推荐'].value_counts().index.tolist()   #获取类目
c = (
    Pie()
    .add(
        """

```

```

        [list(z) for z in zip(tui_type,tui_number)],    #左：类目
    右：数量
    center=["35%", "50%"],
)
.set_global_opts(
    title_opts=opts.TitleOpts(title="推荐占比分布"),
    legend_opts=opts.LegendOpts(orient="vertical",
pos_top="15%", pos_left="2%"),
)
.set_series_opts(label_opts=opts.LabelOpts(formatter="{b} :
{c}"))
)
c.render('推荐占比分布.html')

```

2、运行与测试。

1. 信息实时爬取



The screenshot displays a web application interface. At the top, there is a table with columns: Name, Type, Size, and Value. The table contains 12 rows of data, including book titles, types, sizes, and values. Below the table, there is a 'Console' window showing a list of book recommendations with details such as title, author, publisher, price, and discount.

Name	Type	Size	Value
li	selector.Selector	1	Selector object of parsel.selector module
lis	selector.SelectorList	20	SelectorList object of parsel.selector module
page	int	1	25
press	str	7	时代文艺出版社
price_e	NoneType	1	NoneType object
price_n	str	6	¥12.20
price_r	str	6	¥27.00
price_s	str	4	4.5折
recommend	str	7	99.9%推荐
response	models.Response	1	Response object of requests.models module


Console 1/A X

八次危机：中国的真实经验1949-2009 131652条评论 99.9%推荐 温铁军等著 2013-01-01 东方出版社 ¥37.50 ¥55.00 6.8折 <http://product.dangdang.com/22917090.html>
 日子不慌不忙 我们来日方长（精选季羡林、史铁生、沈从文、梁实秋、汪曾祺等名家经典散文，从日常生活中感悟亲情、友情、爱情）
 18232条评论 100%推荐 季羡林、史铁生等著，紫图图书出品 2022-10-01 中国致公出版社 ¥19.80 ¥55.00 3.6折 <http://product.dangdang.com/29470231.html>
 红鞋子（拼音版） 185815条评论 96.3%推荐 汤素兰 2021-05-01 天天出版社有限责任公司 ¥8.00 ¥20.00 4.0折 <http://product.dangdang.com/29248980.html>
 半小时漫画红楼梦（专治没耐心读红楼梦，这回终于算是读完红楼梦了！红楼梦处处都是梗，曹雪芹就是个段子手） 13989条评论 100%推荐
 陈磊·半小时漫画团队：读客文化 出品 2023-06-05 文汇出版社 ¥29.90 ¥59.90 5.0折 <http://product.dangdang.com/29578957.html>
 地心游记（银火箭少年科幻系列·第2辑，又译《地心历险记》，经典探险科幻小说，引发孩子对自然宇宙的思考） 53853条评论 100%推荐
 【法】儒勒·凡尔纳 著 陈魏卿译；小当当童书馆 出品 2020-04-01 民主与建设出版社 ¥15.80 ¥35.00 4.5折 <http://product.dangdang.com/28532004.html>
 人间词话（王国维先生的代表作，近代较富盛名的词话著作） 605136条评论 99.9%推荐 王国维 著 2015-06-01 北京联合出版公司
 ¥13.40 ¥29.80 4.5折 <http://product.dangdang.com/23715237.html>
 绿野仙踪（中小学生在课外阅读指导丛书）彩插无障碍阅读 智慧熊图书 24263条评论 100%推荐（美）莱曼 弗兰克 鲍姆 2021-03-01 商务
 印书馆 ¥13.40 ¥15.80 8.5折 <http://product.dangdang.com/29223970.html>
 中华上下五千年（中小学生在课外阅读指导丛书）无障碍阅读 彩插励志版 近30万多名读者热评！ 342408条评论 99.9%推荐 邵珠磊编写
 2021-04-01 南方出版社 ¥13.40 ¥15.80 8.5折 <http://product.dangdang.com/23197946.html>
 认知驱动：做成一作对他人很有用的事 44774条评论 100%推荐 周岭 2021-08-30 人民邮电出版社 ¥29.90 ¥59.80 5.0折 <http://product.dangdang.com/29295726.html>
 晚熟的人（莫言新书） 443259条评论 100%推荐 莫言 2020-07-01 人民文学出版社 ¥29.50 ¥59.00 5.0折 <http://product.dangdang.com/28994936.html>
 月亮和六便士（毛姆代表作之一，全新导读+无删节详注版） 615685条评论 99.9%推荐（英）毛姆 著 苏福忠 译 2017-09-01 时代文艺
 出版社 ¥12.20 ¥27.00 4.5折 <http://product.dangdang.com/25126128.html>

3.

2. 数据分析

推荐占比分布



3、难点和亮点。

一、难点

1. 数据爬取难点：爬取网站上的数据可能会遇到反爬虫机制，需要采取一些策略来规避这些障碍，以确保数据的完整性和准确性。
2. 数据量大：从多个页面获取图书信息可能会导致大量数据，需要有效的存储和处理方式，以应对数据量大的挑战。

二、亮点

1. 全面的数据获取：项目通过爬取多个页面的数据，提供了大量的图书信息，满足了用户对全面数据的需求，帮助用户做出明智的决策。
2. 深入的数据分析：项目提供了强大的数据分析功能，允许用户深入了解不同方面的数据，包括推荐指数、出版社、价格等，从而提供深刻的见解。
3. 可视化工具：通过可视化工具，项目将复杂的数据呈现为直观的图表，使用户能够更容易理解和分享数据。

四、总结体会

项目旨在为用户提供一个强大的数据爬取、分析和可视化工具，以满足不同利益相关者的需求。

1. 多功能工具：项目具有多功能性，既可以用于市场分析，也可以用于满足普通读者的阅读需求。它既可以为专业用户提供深入的数据分析，又可以帮助普通读者更好地选择图书。
2. 全面的数据获取：通过数据爬取功能，项目提供了大量的图书信息，从不同角度满足了用户的需求。
3. 深度数据分析：项目提供了深度数据分析功能，用户可以探索数据的多个方面，包括推荐指数、出版社、价格等。

4. 数据可视化：可视化工具使数据更具吸引力和易于理解。用户可以通过图表更快速地了解数据，而不必深入研究原始数据。

5. 用户自定义：项目允许用户自定义数据分析和可视化，满足不同用户的需求。这种灵活性使其适用于各种用例。

6. 结果输出：用户可以保存分析结果和图表，以供后续查看和分享。这种功能有助于用户记录他们的发现和决策。

这个项目为市场参与者和读者提供了一个强大的工具，有助于他们更好地了解图书市场、做出明智的决策和满足他们的阅读需求。项目的多功能性、全面性和深度分析使其成为一个有价值的工具。