

学号： 2106410113



沈阳建筑大学

大数据技术基础 综合设计报告

2023 年秋季学期

学 院： 计算机科学与工程学院

专业班级： 计算机 2101 班

姓 名： 张艳芳

一、题目名称：Python 开发网易云音乐榜单爬虫及歌词分析软件设计与实现

二、分析与设计：

1、需求分析。

本次设计旨在介绍使用 Python 编写的网易云音乐榜单爬虫程序，以及对歌曲歌词进行分析的功能。通过该程序，用户可以爬取指定榜单的歌曲并保存到本地，同时提取歌曲的歌词并进行分词统计。

2、功能设计。

1) 网易云音乐榜单爬虫功能：

- 用户输入榜单名称和榜单 ID。
- 发送 HTTP 请求获取榜单页面的 HTML 数据。
- 解析 HTML 数据提取歌曲 ID 和歌曲名称。
- 拼接歌曲链接并访问获取音乐数据。
- 将音乐数据保存到本地文件夹中。

2) 歌词提取与分词统计功能：

- 用户输入歌曲 ID。
- 构建歌词 API 请求 URL 并发送请求。
- 解析返回的 JSON 数据提取歌词文本。
- 去除歌词中的时间标签和其他特殊字符。
- 将处理后的歌词保存到文本文件中。
- 使用 jieba 库对歌词进行分词。
- 统计词语频率并生成词频统计表格。

三、系统实现

1、程序实现。

```
import requests
import re
import os
import json
import jieba
from openpyxl import Workbook

url = f"https://music.163.com/discover/toplist?id={rank_id}"
headers = {
    'User-Agent': 'Mozilla/5.0 (Windows NT 10.0; Win64; x64)
AppleWebKit/537.36 (KHTML, like Gecko) Chrome/103.0.0.0 Safari/537.36'
}
# 发送请求
response = requests.get(url=url, headers=headers)
# 获取数据
html_data = response.text
```

```

# 解析数据
info_list = re.findall('<li><a href="/song/?id=(.*?)">(.*?)</a></li>', html_data)
for info in info_list:
    music_id = info[0]
    music_name = info[1]
# 将音乐链接拼接好
    music_url = 'http://music.163.com/song/media/outer/url?id=' + music_id
# 访问音乐链接 获取音乐数据
    music_data = requests.get(music_url).content
# 将音乐保存
    music_name = re.sub(r'[\\:*\?<>|]', '_', music_name) #title 中包含了特殊字
符，导致文件夹创建失败，将特殊字符转换为_
    with open(f'{filename}/{music_id}-{music_name}.mp3', mode='wb') as f:
        f.write(music_data)
#根据歌词 id 提取歌词
    lrc_url = 'http://music.163.com/api/song/lyric?' + 'id=' + str(music_ID) +
'&lv=1&kv=1&tv=-1'
    lyric = requests.get(lrc_url)
    json_obj = lyric.text
    j = json.loads(json_obj)
    lrc = j['lrc']['lyric']
    pat = re.compile(r'\.[*\]')
    lrc = re.sub(pat, '', lrc)
    lrc = lrc.strip()
    print(lrc)
# 读词
    file = open("D:/Python/歌词.txt", 'r', encoding='utf-8') # Specify the correct
encoding
    lyric_str = file.read()
    seg = jieba.cut(lyric_str) # jieba 分词
    word_list = []
    word_dict = {}
    for each in seg:
        if len(each) > 1:
            word_list.append(each)
    for index in word_list:
        if index in word_dict:
            word_dict[index] += 1
        else:

```

```

word_dict[index] = 1
sorted(word_dict.items(), key=lambda e: e[1], reverse=False)
# 将分词和词频输出到 excel 中
file = Workbook()
sheet = file.active
sheet.title = "分词与词频"
# 添加列名
sheet.cell(row=1, column=1, value="歌词")
sheet.cell(row=1, column=2, value="频率")
row_num = 2
for item in word_dict.items():
    word = item[0]
    frequency = item[1]
    sheet.cell(row=row_num, column=1, value=word)
    sheet.cell(row=row_num, column=2, value=frequency)
    row_num += 1

```

2、运行与测试。

1) 运行程序

```
In [73]: runfile('D:/Python/网易云音乐榜单.py', wdir='D:/Python')
```

请输入您想要爬取的榜单名称：网络热歌榜

请输入您想要爬取的榜单id: 6723173524

我看过 <http://music.163.com/song/media/outer/url?id=2075085618>

鲜花 (Live) <http://music.163.com/song/media/outer/url?id=2088079571>

圣山 <http://music.163.com/song/media/outer/url?id=2084366052>

我要你看穿我不是杀了我 <http://music.163.com/song/media/outer/url?id=2066050870>

鲜花 <http://music.163.com/song/media/outer/url?id=2086327879>

我只能离开 <http://music.163.com/song/media/outer/url?id=2078080232>

主动 <http://music.163.com/song/media/outer/url?id=2074440239>

太聪明 Beat <http://music.163.com/song/media/outer/url?id=2080861627>

瞬 <http://music.163.com/song/media/outer/url?id=2063864551>

太阳 <http://music.163.com/song/media/outer/url?id=1385856956>

可在文件夹中查看并播放以上榜单音乐

请输入您想要提取歌词的歌曲ID: 2075085618

作词 : 阿彻

作曲 : 阿彻

编曲 : 丁成玉CyberD

制作人 : 阿彻

混音 : Zitto

统筹 : 龙龙

企划 : AiryX/七步

监制 : 袁晓童/王子

营销 : 七步

出品 : 网易·云上x雪球音乐

“亲爱的不要再说你还爱我

因为看过你爱我的样子

我看过的最美的落日


是你陪我看海的样子

如你说早已经没有了意义
那时候语气也冷的像冰
你正在远去
而我在恍惚中看到了你曾经给我的炽烈
当初的快乐却变成了癌细胞无情的扩散在我留的世界
可最后的最后你还能张口说爱我
也许是你也会愧疚 也许是黑夜里我想的太多
你站在迷雾的对面 留下的话语毒药是甜的
别再说爱我 别再说爱我 我看过那时 你爱我的颜色
“我看过的最美的落日
是你陪我看海的样子
就算错过只能到此为止
至少我看过你爱我的样子”
歌词已写入文件： D:/Python/歌词.txt
词频统计结果已保存到： D:/Python/词频.xlsx


2) 展示文件夹内容

我的电脑 > Data (D:) > Python > 网络热歌榜					在 网络...
名称	#	标题	参与创作的艺术家	唱片集	
 1385856956-太阳					
 2063864551-瞬					
 2066050870-我要...					
 2074440239-主 动					
 2075085618-我看过					
 2078080232-我只...					
 2080861627-太聪...					
 2084366052-圣山					
 2086327879-鲜花					
 2088079571-鲜花 (...)					

3) 播放音乐



4) 展示歌词.txt



5) 展示词频. xlsx

歌词	频率
1 歌词	1
2 作词	1
3 阿桐	1
4 作曲	1
5 编曲	1
6 丁成玉	1
7 CyberD	1
8 制作	1
9 混音	1
10 Zitto	1
11 统筹	1
12 龙龙	1
13 企划	1
14 AitryA	1
15 七步	2
16 监制	1
17 赖晓童	1
18 王子	1
19 营销	1
20 出品	1
21 网易	1
22 云上	1
23 雪球	1
24 音乐	1
25 张发	1
26 不爱	1
27 再说	3
28 因为	1
29 看过	11
30 林子	5

3、难点和亮点。

亮点：

- 1) 使用合适的 User-Agent 头部信息，以模拟浏览器发送请求，避免被网站识别为爬虫而拒绝访问。
- 2) 使用文件操作将音乐数据保存到本地的文件夹中。
- 3) 处理特殊字符，将歌曲名称中的特殊字符转换为下划线，以避免文件操作的异常。
- 4) 通过程序自动爬取网易云音乐榜单的歌曲数据，节省用户手动搜索的时间。
- 5) 对歌曲的歌词进行分词，并统计词语的频率，帮助用户了解歌曲的内容特点

这些亮点使得程序能够有效地获取网页数据、解析数据、下载音乐并保存，同时处理了一些可能出现的异常情况，提高了程序的可靠性和稳定性。

难点：

- 1) 使用 jieba 库进行中文分词，需要处理好中文编码和词语的统计。
- 2) 爬虫的权限与音乐权限相关，该爬虫程序爬取不了 VIP 音乐。

四、总结体会

通过本次设计，我们成功实现了一个音乐下载程序，能够从网易云音乐的榜单中获取音乐列表，并将音乐文件保存到本地。这个程序可以为用户提供便利的音乐下载服务。在实现过程中，我充分运用了 Python 编程语言和相关的库，通过发送 HTTP 请求、解析 HTML 内容和保存文件等操作，实现了系统的各项功能。其中，在设计过程中，我学会了如何在请求网页的时候伪装自己以成功获取数据以及如何处理歌词文本和进行分词统计。

在一次程序测试中，我发现程序在同一个音乐文件后报错，经过我的检查与搜索，我发现了出现错误的原因是 `title` 中包含了特殊字符，导致文件夹创建失败，通过将特殊字符转换为 ‘_’ 即可解决。在设计过程中发现问题，解决问题，让我对于知识的理解更加透彻。