

学号： 2106410102



沈阳建筑大学

# 大数据技术基础 综合设计报告

2023 年秋季学期

学 院： 计算机科学与工程学院

专业班级： 计算机 2101 班

姓 名： 文延欢

一、题目名称：Python 开发爬虫小说软件设计与实现

二、分析与设计：

1、需求分析。

随着生活节奏的加快以及互联网的普及，越来越多的人放弃耗费时间与金钱的纸质书，选择阅读更加便捷的电子书。在经济的不断发展和大环境趋势下，有了各种各样的电子书网站，人们有了更多的选择。随之产生的问题是，人们在网站上阅读，每次进入都需要等待，如果遇到网络不好的情况下甚至无法进入，对大众的阅读体验造成了不好的影响。为了解决这一问题，我设计了一种爬虫小说的程序，只要读者输入某一网站的书籍详情页编码，就可以一次性下载，离线情况下也可以无障碍阅读。

2、功能设计。

本软件用于爬虫电子书网站的电子书，并将其下载到本地，以便阅读。程序的主要功能实现步骤如下：

(1) 创建存放下载小说的文件名

(2) 向网站发起请求

(3) 利用 css 解析器对爬取的 HTML 文件进行特征提取

(4) 爬取书籍目录指向的链接，利用 css 解析器将章节内容写入文件

控制台会提示下载进度，提醒用户下载情况。程序运行结束后，用户可以打开最先创建的文件夹，里面存放有小说章节内容的 txt 文件。

三、系统实现

1、程序实现。


代码：

```
rid = input('输入书名 ID: ')
link = f'https://www.bqg70.com/book/{rid}/'
html_data = requests.get(url=link, headers=headers).text
selector_2 = parsel.Selector(html_data)
divs = selector_2.css('.listmain dd')
for div in divs:
    title = div.css('a::text').get()
    href = div.css('a::attr(href)').get()
    url = 'https://www.bqg70.com' + href
    try:
        response = requests.get(url=url, headers=headers)
        selector = parsel.Selector(response.text)
        book = selector.css('#chaptercontent::text').getall()
        book = '\n'.join(book)
        # 数据保存
        with open(filename + title + '.txt', mode='a', encoding='utf-8') as f:
            f.write(book)
```

```
        print('正在下载章节: ', title)
    except Exception as e:
        print(e)
```

### 3、运行与测试。

输入书名 id，开始对小说章节进行下载，部分运行结果如下图所示：



输入多个不同的书名 id 对程序进行测试，测试部分运行结果如下：

```
IPython控制台
控制台 1/A X
输入书名ID: 99015
正在下载章节: 第1章 前言
正在下载章节: 第2章 无所不能的回纥人
正在下载章节: 第3章 天照顾的回纥人
正在下载章节: 第4章 美食不可辜负! (感谢棠棠白银盟)
正在下载章节: 第5章 我不想当回纥人了 (感谢老友们打赏)
正在下载章节: 第6章 云初是石头娃变的
正在下载章节: 第7章 植物学是一门有用的学问
正在下载章节: 第8章 回纥人的葬礼
正在下载章节: 第9章 回纥人权力的由来
正在下载章节: 第10章 魔鬼的孩子
```

```
IPython控制台
控制台 1/A X
输入书名ID: 511
正在下载章节: 侠客列传
正在下载章节: 第一章 星空中的青铜巨棺
正在下载章节: 第二章 素问
正在下载章节: 第三章 今昔
正在下载章节: 第四章 荒古铜刻
正在下载章节: 第五章 李小曼
正在下载章节: 第六章 封禅之地
正在下载章节: 第七章 五色祭坛
正在下载章节: 第八章 星空古路
正在下载章节: 第九章 铜棺内第三十人
Failed to parse: https://www.bqg70.comjavascript:dd_show()
正在下载章节: 第十章 苍茫大地
正在下载章节: 第十一章 光源
正在下载章节: 第十二章 荧惑
```

经过与网页原内容进行比对后,证明了程序的可行性。

#### 4、难点和亮点。

难点: 对网页文件爬取后,里面的数据多且杂,此时就需要选出程序所需元素,将多余的元素抛弃掉。本程序利用 `parsel` 库,创建 `Selector` 对象,引用 `css` 解析器对爬取的 `HTML` 文件进行内容解析与提取,此处的难点是,需要在网页源码检查所需数据的特征性标签或者类名,用于提取正确的数据,此部分根据网页的变化而有所变化,需要随机应变。

亮点: 本程序的亮点在于提取数据时运用了循环语句,在抓取小说章节内容(即新的一个网页),运用 `getall()` 方法将全部内容抓取,然后用回车来对内容分段。抓取的每一章节内容都被存放在了不同的文件夹里面,并且用章节名命名,方便了用户查找和阅读。

#### 四、总结体会

通过这一次的程序设计，我学会了如何运用 python 语言抓取网页内容。在程序设计过程中，会遇到很多难题，比如如何在请求网页的时候伪装自己以成功获取数据:打开一个网页，右击检查，可以找到 header 里面的 User-Agent，复制粘贴进自己的 headers 变量。

以及如何从网页的 HTML 文件提取出我们需要的内容，以及如何将其分别写入不同的文件夹，并为其命名。遇到这些问题后，通过网络以及书籍查询，我得到了解决办法，并且记忆深刻。在实践中发现问题，解决问题，也让我对于旧知识的理解更加透彻，对新知识的输入更加深刻。