

学号： 2106410111



沈阳建筑大学

大数据技术基础 综合设计报告

2023 年秋季学期

学 院： 计算机科学与工程学院

专业班级： 计算机 2101 班

姓 名： 毕晓岩

正文格式：中文宋体、英文数字 Times New Roman、小四、单倍行距。

一、题目名称：基于 python 爬取虎扑网站信息

二、分析与设计：

1、需求分析

快速浏览虎扑网站首页所有信息。

2、功能设计

爬取虎扑网站首页所有信息。

三、系统实现

1、程序实现

```
from bs4 import BeautifulSoup
import requests
import csv
def hupu():
    li = []
    # 虎扑 获取主页标题
    url = 'https://bbs.hupu.com/'
    headers = {
        'user-agent': 'Mozilla/5.0 (Windows NT 10.0; Win64; x64)
AppleWebKit/537.36 (KHTML, like Gecko) Chrome/106.0.0.0 Safari/537.36
Edg/106.0.1370.42'
    }
    req = requests.get(url, headers=headers).content.decode('utf-8')
    soup = BeautifulSoup(req, 'lxml')
    p = soup.find_all('span', class_='t-title')
    for each in p:
        li1 = [each.text]
```

```

        li.append(li1)

    with open('mmic.txt', 'a+') as f:

        f.writelines(each.text)

        f.writelines('\n')

    return li

#print(hupu())

```

2、运行与测试

```

C:\Users\毕晓岩\PycharmProjects\pythonProject5\venv\Scripts\python.exe C:\Users\毕晓岩\PycharmProjects\pythonProject5\main.py

Process finished with exit code 0

```

```

1  我们聚会又没有邀请你，请你离开。
2  起家以色列人李春红的历史，她的所作所为远比她的傲慢让人愤慨！
3  绿街的兄弟们，终于轮到我了.....
4  女子和男同事进电梯前打闹嬉戏，进电梯后男同事想更进一步结果悲剧喜提七日免费游
5  月曜中国采访四川成都篇，喜剧效果拉满！
6  昨晚吃火锅遇到的妹子
7  我是那个“暗恋女下属的”，现在准备冲了【已放弃】
8  帮印度建了6年高铁后，日本人想跑路了
9  太解压了
10 白酒购酒指南：酒价还有下跌空间
11  【流言板】开启新的生活！波边雄太妻子晒照已经从纽约搬到了菲尼克斯
12  【流言板】恐怖如斯！季前赛太阳3次半场破70+，唯一一场三巨头缺席
13  【流言板】在GM调查中，惠特莫尔以43%的票选率被选为本届最大选秀捡漏
14  【流言板】库里是史上唯一单季场均得分30+，命中率超50%/40%/90%球员
15  【流言板】惠特莫尔谈隔扣被取消：当时看到有人在身前，就直接起跳了
16  【流言板】恐怖的天赋！惠特莫尔反击完成暴力隔扣，可惜被吹进攻犯规
17  【流言板】布朗：我被骑士解雇后连休两年，而詹姆斯连续征战21年
18  【流言板】火药味！阿门与索汉爆发小冲突，随后狄龙与科林斯互相推搡
19  【流言板】经典再现！西蒙斯再次上演诺维斯基转身金鸡独立投篮
20  【流言板】纳兹-里德：我长高了，我从2米03长到了2米08，这让我很吃惊
21  看了日本B联赛后卫的出手数，真是委屈国产后卫了，外援政策真是坑！
22  【流言板】北大男篮功勋教练张剑退休，执教34年曾率队四夺CUBA冠军
23  【流言板】马健：男篮需要大手术但要知道症状，否则都是断了线的气球
24  山西女篮晒接机视频：咱的超级外援托马斯来了
25  【流言板】相约广州！龙狮新赛季主场票价：单场最高1980元，最低90元
26  杨力维晒与杨舒予一同回昆明生活记录：跟我一起回快乐老家
27  齐麟分享生活碎片：坦然面对就是成长的开始
28  辽宁队训练师晒视频：郭艾伦张镇麟各自加练，场边欢乐畅聊
29  广东缺的是内线教练
30  今年这配置说我不想争冠都是骗人的，唯一的弱点就是中锋，前几的球队貌似内线都比我们强
31  【韩网翻译】Daeny讲述加入WBG到晋级世界赛的过程：季后赛更重要
32  2023全球总决赛LPL赛区出征片《LPL拼尽一切的理由》
33  【情报站】LOL官推发文：TheShy重回全球总决赛
34  【情报站】Reddit网友发现369可用369胜达成世界赛夺冠：巧合还是注定
35  【情报站】Faker：S13所有中单我的幽默细胞最超群，Oner打决赛会紧张
36  【情报站】Zeus回应明年去处：第一次成为自由人，不知道会变成什么样
37  【翻译团】Chovy：LCK和LPL都很强，我不认为两者之一有统治地位
38  【韩网翻译】Scout：第一轮未抽到T1很遗憾，想在淘汰赛和Faker交手

```

3、难点和亮点

难点：不同网站的页面结构和布局可能各不相同，这就需要爬虫程序具备一定的灵活性来处理不同的网页结构。一些网站采用了 JavaScript 等技术来实现页面内容的动态加载，这就意味着爬虫程序需要能够模拟浏览器行为，执行 JavaScript 代码，获取完整的页面内容。这需要使用一些特殊的库或工具，如 Selenium、PhantomJS 等。为了防止被过度爬取或者保护敏感信息，一些网站会采取反爬虫策略。例如，限制访问频率、设置登录验证、使用动态生成的 URL 等。爬虫程序需要具备一定的策略和技巧来绕过这些限制，如设置合理的请求头、使用代理 IP 等。爬取到的网页内容通常包含大量的噪音数据，如广告、无关信息等。爬虫程序需要对这些数据进行清洗和处理，提取出真正需要的信息。这可能需要使用正则表达式、XPath 等技术来进行数据的提取和解析。网站有许多不相关的其他信息，需要将其筛选掉。

亮点：Python 拥有众多优秀的爬虫库和工具，如 Requests、Beautiful Soup、Scrapy 等。这些库提供了简洁易用的 API，能够大大简化爬虫程序的开发和调试过程。Python 提供了多线程和异步编程的支持，可以加快爬取速度，提高效率。多线程可以同时处理多个请求，而异步编程则可以在等待网络响应时执行其他任务，充分利用计算资源。Python 可以方便地将爬取到的数据存储到数据库或文件中，如 MySQL、MongoDB、CSV 等。同时，Python 还提供了丰富的数据分析和处理库，如 Pandas、NumPy 等，可以对爬取到的数据进行进一步的分析和处理。按虎扑网站数据顺序爬取并调整排版使其更加工整，使我们能够对网站首页信息一目了然。

四、总结体会

本次基于 python 的综合设计，让我对爬虫有了初步的了解与运用。在下载 pycharm 与配置 python 环境也熟悉了一些软件下载与配置的流程与操作。在编译过程中了解了 requests package 和 beautiful soup。对于下载不了的 package 我学会了用命令提示符进行下载。对于额外的，我还了解了 pandas package。

通过学习，学会如何找到网站的 url 和 header。总的来说，本次综合设计收获还是蛮大的。我会继续闲暇时间继续在 python 领域探索。