

学号： 2104240127



沈阳建筑大学

大数据技术基础 综合设计报告

2023 年秋季学期

学 院： 计算机科学与工程学院

专业班级： 计算机 2101 班

姓 名： 常治远

一、题目名称：

Python 爬虫：爬取天天基金数据信息

二、分析与设计：

1、需求分析。

天天基金是中国最受欢迎的基金信息平台之一，它提供了广泛的基金数据，包括基金净值、持仓股票、历史走势等信息。为了满足投资者对实时和历史基金数据的需求，我们计划设计并实现一个 Python 爬虫，用于自动化地获取和存储天天基金的数据信息。具体应用是通过本程序能够获取到天天基金开放式基金排行了解到各个基金的信息情况，并对于获取的数据保存于文件中，然后能够生成相应指标的走势图，了解各基金的情况。实现数据的可视化。

2、功能设计。

（1）爬取基金数据

使用 requests 库发送请求后，获取响应的 HTML 数据，使用 lxml 库解析 HTML 数据，使用 CSS 选择器提取基金信息，包括基金名称、基金代码、单位净值、累计净值、日增长率等。

（2）存储数据

打开 CSV 文件以写入数据，设置编码为 UTF-8。写入数据，包括表头和基金信息。以 CSV 格式保存基金数据，每行包括基金名称、基金代码、单位净值、累计净值、日增长率。

（3）数据可视化

读取已保存的 CSV 文件，使用 pandas 库。选择前 10 个基金的数据，包括基金名称和日增长率。使用 matplotlib 库创建日增长率柱状图，横轴为基金名称，纵轴为日增长率。显示图表。

（4）循环爬取多页数据：

使用 for 循环，可以指定要爬取的页面范围。构建不同页的 URL，确保能够获取多页数据。在循环中发送 HTTP 请求，获取数据，并逐页保存到 CSV 文件中。

三、系统实现

1、程序实现

```
from turtle import pd
import requests
import re
import csv
import pandas as pd
headers = {
    'Cookie': 'qgqp_b_id=becac21bf0708503e7c2d1be2d923210;
websiteoptg_api_time=1697546041659; _adsame_fullscreen_14694=1;
st_si=32082183784155; st_asl=delete;
```

```

ASP.NET_SessionId=bmc4wjjudgpicye0idowwufqa; st_pvi=07932658011753;
st_sp=2023-10-17%2020%3A34%3A02;
st_inirUrl=https%3A%2F%2Fen.bing.com%2F; st_sn=3;
st_psi=20231017232612770-112200304021-8797404737',
    'Host': 'fund.eastmoney.com',
    'Referer': 'http://fund.eastmoney.com/data/fundranking.html',
    'User-Agent': 'Mozilla/5.0 (Windows NT 10.0; Win64; x64)
AppleWebKit/537.36 (KHTML, like Gecko) Chrome/118.0.0.0 Safari/537.36
Edg/118.0.2088.46'
}
# for page in range(1, 2):
# print(f'-----正在爬取第{page}页内容-----')
url =
f'http://fund.eastmoney.com/data/rankhandler.aspx?op=ph&dt=kf&ft=all&rs=&gs=0
&sc=1nzf&st=desc&sd=2022-10-17&ed=2023-10-17&qdii=&tabSubtype=,,,,,&pi=
1&pn=50&dx=1'
response = requests.get(url=url, headers=headers)
data = response.text
data_str = re.findall('[(.*)]', data)[0]
tuple_data = eval(data_str)
for td in tuple_data:
    td_list = td.split(',')
    with open('股票.csv', mode='a', encoding='utf-8', newline='') as f:
        csv_write = csv.writer(f) # 创建 csv 文件写入对象
        csv_write.writerow(td_list)
    print(td)
import matplotlib.pyplot as plt
fund_names = pd.read_csv('股票.csv', header=None)
print(fund_names)
data = fund_names.loc[:10, [0, 6]]
print(data)
data[[0, 6]].plot(kind='bar', title="基金比率分布", x=0, y=6)
plt.show()


```

2、运行与测试。

(1) 运行结果截图

Money							
D:\python\python.exe D:\pythonProject\Money.py							
003384	金鹰添盈纯债债券A	JYTYCZZQA	2023-10-17	1.9344	-0.2843	-0.02	-0.01
012623	金鹰添盈纯债债券C	JYTYCZZQC	2023-10-17	1.8831	-0.1831	-0.02	-0.02
290012	泰信行业精选混合A	TXHYJXHHA	2023-10-17	1.7040	-0.2840	-0.12	-0.18
002583	泰信行业精选混合C	TXHYJXHHC	2023-10-17	1.7010	-0.2810	-0.12	-0.19
012768	华夏中证动漫游戏ETF联接A	HXZZDMYXETFLJA	2023-10-17	1.1019	-0.1019	-0.19	-0.22
012728	国泰中证动漫游戏ETF联接A	GTZZDMYXETFLJA	2023-10-17	1.1126	-0.1126	-0.17	-0.07
012769	华夏中证动漫游戏ETF联接C	HXZZDMYXETFLJC	2023-10-17	1.0950	-0.0950	-0.19	-0.23
012729	国泰中证动漫游戏ETF联接C	GTZZDMYXETFLJC	2023-10-17	1.1050	-0.1050	-0.16	-0.07
270042	广发纳斯达克100ETF联接人民币(QDII)A	GFNSDK100ETFLJRMHQDIIA	2023-10-16	4.6747	4.9447	1.20	0.80
006479	广发纳斯达克100ETF联接人民币(QDII)C	GFNSDK100ETFLJRMHQDIIIC	2023-10-16	4.6188	4.6188	1.20	0.80
006373	国富全球科技互联混合人民币	GFQKJHLHHRMB	2023-10-16	2.4109	2.4109	0.93	0.55
016055	博时纳斯达克100ETF发起式联接(QDII)A人民币	BSNSDK100ETFFQSLJQDIIRMB	2023-10-16	1.2234	1.2234	1.01	1.04
040046	华安纳斯达克100ETF联接(QDII)A	HANSOK100ETFLJQDIIA	2023-10-16	4.7520	4.7520	1.15	0.76
270023	广发全球精选股票(QDII)	GFQJXGPQDII	2023-10-17	2.7370	3.1760	0.15	-0.26
016057	博时纳斯达克100ETF发起式联接(QDII)C人民币	BSNSDK100ETFFQSLJQDIICRMB	2023-10-16	1.2173	1.2173	1.04	-0.24
014978	华安纳斯达克100ETF联接(QDII)C	HANSOK100ETFLJQDIIC	2023-10-16	4.6810	4.6810	1.15	0.75
000834	大成纳斯达克100ETF联接(QDII)A	DCNSDK100ETFLJQDIIA	2023-10-17	3.6810	3.6810	-0.32	-0.16
164818	工银中证传媒指数(LOF)	GYZZCMSLLOFA	2023-10-17	0.9074	0.2777	-0.14	-0.34
009225	天弘中证中美互联网(QDII)A	THZZMHLWQDIIA	2023-10-17	0.9669	0.9669	0.26	-1.04
0	1	2	...	22	23	24	
0	3384	金鹰添盈纯债债券A	JYTYCZZQA	...	0.08%	1.0	121.45
1	12623	金鹰添盈纯债债券C	JYTYCZZQC	...	NaN	NaN	NaN
2	290012	泰信行业精选混合A	TXHYJXHHA	...	0.15%	1.0	115.70
3	2583	泰信行业精选混合C	TXHYJXHHC	...	0.00%	0.0	115.48
4	12768	华夏中证动漫游戏ETF联接A	HXZZDMYXETFLJA	...	0.12%	1.0	NaN
...	...	...	...	...	...	...	...
245	162102	金鹰中小盘精选混合A	JYZXPJXHHA	...	0.15%	1.0	153.41
246	320015	诺安行业轮动混合A	NAHYLDHHA	...	0.12%	1.0	115.55
247	4596	中科沃土沃安中短利率A	ZKWTWAZDLLA	...	0.04%	1.0	44.32
248	43	嘉实美国成长股票人民币	JSMGCZGPRMB	...	0.15%	1.0	76.91
249	16114	东方区域发展混合	DFQYFZHH	...	0.15%	1.0	80.60

(2) 图形的显示



(3) 生成文件保存

A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	T
3384	金鹰添盈利	JYTCZ2QA	2023/10/17	1.9344	2.2843	-0.02	-0.01	0.1	0.3	135.75	136.11	127.75	107.7	135.88	143.33	2017/1/11	1	136.113	0.8
12623	金鹰添盈利	JYTCZ2QC	2023/10/17	1.8831	2.1031	-0.02	-0.02	0.1	0.3	130.62	128.84	120.82		128.07	104.12	2021/6/8	1	128.842	
290012	泰信行业利	TXHYJXHHA	2023/10/17	1.704	2.284	-0.12	-2.18	-7.74	-14.53	-11.67	49.07	35.74	11.25	20.42	154.94	2012/2/22	1	49.072	1.5
2583	泰信行业利	TXHYJXHHC	2023/10/17	1.701	2.281	-0.12	-2.19	-7.8	-14.6	-11.73	48.83	35.52	11.07	20.23	63.74	2016/5/5	1	48.8327	1.5
12768	华夏中证	HXZZDMYXE	2023/10/17	1.1019	1.1019	-0.19	-4.22	-2.13	-19.36	-20.36	44.38	12.83		34	10.19	2021/8/31	1	44.3789	1.2
12728	国泰中证	GTZZDMYXE	2023/10/17	1.1126	1.1126	-0.17	-4.07	-1.92	-18.28	-18.44	44.23	16.51		34.18	11.26	2021/6/24	1	44.2313	1.0
270023	广发全球利	GFQJZ2PQF	2023/10/16	2.733	3.172	0.96	0.63	-0.38	-1.97	25.54	44.07	-13.98	-7.2	46.46	262.88	2010/8/18	1		1.6
12769	华夏中证	HXZZDMYXE	2023/10/17	1.095	1.095	-0.19	-4.23	-2.16	-19.41	-20.48	43.97	12.17		33.68	9.5	2021/8/31	1	43.9653	
12729	国泰中证	GTZZDMYXE	2023/10/17	1.105	1.105	-0.16	-4.07	-1.94	-18.34	-18.56	43.81	15.83		33.86	10.5	2021/6/24	1	43.8053	
270042	广发纳斯达克	GFNSDK100F	2023/10/16	4.6747	4.9447	1.2	0.8	-0.35	-1.75	20.73	42.23	8.65	33.14	41.62	467.44	2012/8/15	1		1.3
834	大成纳斯达克	DCNSDK100F	2023/10/16	3.693	3.693	1.15	0.71	-0.11	-1.83	20.92	42.2	10.3	34.44	41.66	269.3	#####	1		1.2
6479	广发纳斯达克	GFNSDK100F	2023/10/16	4.6188	4.6188	1.2	0.8	-0.37	-1.8	20.6	41.93	8.12	32.25	41.39	109.78	#####	1		
6373	国富全球利	GFQJZ2HLH	2023/10/16	2.4109	2.4109	0.93	0.55	0.39	-2.63	15.07	41.73	0.17	24.01	32.02	141.09	#####	1		1.5
5698	华夏全球利	HXQJZ2JXFH	2023/10/16	1.2656	1.2656	1.32	1.27	1.48	-1.41	25.42	40.72	-12.42	-7.55	44.97	26.56	2018/4/17	1		1.5
16055	博时纳斯达克	BSNSDK100F	2023/10/16	1.2234	1.2234	1.01	1.04	-0.23	-1.92	19.95	40.46			40.19	22.34	2022/7/26	1		1.0
539001	建信纳斯达克	JXNSDK100F	2023/10/16	1.9349	1.9349	1.19	0.81	-0.14	-1.62	20.56	40.11	11.9	24.27	41.36	93.49	2010/9/14	1		1.2
40046	华安纳斯达克	HANSDK100F	2023/10/16	4.752	4.752	1.15	0.76	-0.34	-2.16	20.3	40.09	8.49	32.29	41.34	375.2	2013/8/2	1		1.2
1668	汇添富全球	HTFQZ2JHLH	2023/10/16	2.652	2.652	0.84	1.07	0.15	-1.34	18.6	40.02	-6.91	-0.79	34.01	166.27	2017/1/25	1		1.6
9225	天弘中证	THZZZ2MHLW	2023/10/16	0.9644	0.9644	0.11	-0.29	-3.1	-3.53	13.79	40.01	-15.74	-17.13	27.99	-3.56	2020/5/27	1		1.0
16057	博时纳斯达克	BSNSDK100F	2023/10/16	1.2173	1.2173	1	1.04	-0.24	-1.99	19.77	39.92			39.74	21.73	2022/7/26	1		
15299	华夏纳斯达克	HXNSDK100F	2023/10/16	1.193	1.193	1.18	0.97	0.32	-0.77	21.56	39.88			41.6	19.3	2022/4/14	1		1.2
14978	华安纳斯达克	HANSDK100F	2023/10/16	4.681	4.681	1.15	0.75	-0.36	-2.21	20.21	39.77			41.04	18.33	2022/2/22	1		
9226	天弘中证	THZZZ2MHLW	2023/10/16	0.956	0.956	0.12	-0.29	-3.13	-3.6	13.65	39.64	-16.16	-17.76	27.72	-4.4	2020/5/27	1		
12752	建信纳斯达克	JXNSDK100F	2023/10/16	1.8988	1.8988	1.18	0.81	-0.16	-1.69	20.42	39.59	9.24		40.99	9.21	2021/9/22	1		
15300	华夏纳斯达克	HXNSDK100F	2023/10/16	1.1877	1.1877	1.18	0.98	0.3	-0.53	21.39	39.45			41.28	18.77	2022/4/14	1		
15002	汇添富全球	HTFQZ2JHLH	2023/10/16	2.625	2.625	0.81	1	0.08	-1.54	18.19	39.11			33.32	23.18	2022/3/7	1		
16532	嘉实纳斯达克	JSNSDK100F	2023/10/16	1.2837	1.2837	1.14	0.78	-0.31	-2.32	19.77	38.84			39.87	28.37	2022/9/15	1		1.0
16533	嘉实纳斯达克	JSNSDK100F	2023/10/16	1.2788	1.2788	1.15	0.78	-0.32	-2.37	19.64	38.4			39.47	27.88	2022/9/15	1		
164818	工银中证	GYZZCMZSLA	2023/10/17	0.9074	0.2777	-0.14	-3.14	-2.07	-13.32	-12.83	37.05	9.48	-16.88	24.39	-73.66	2015/5/21	1	37.0488	1.0
10677	工银中证	GYZZCMZSLA	2023/10/17	0.9009	0.9009	-0.14	-3.15	-2.1	-13.38	-12.94	36.71	8.94		24.13	-10.18	#####	1	36.7071	

3、难点和亮点。

难点：正则表达式的使用，它用于从HTML页面中提取所需的数据。正则表达式需要根据页面的结构和数据规模进行精确的编写。

亮点：程序的结构清晰，通过合理的循环和逻辑，能够自动获取多页数据，然后进行可视化展示。这是一个典型的数据爬取和分析的流程。

总的来说，这个程序的难点在于数据提取和正则表达式的使用，亮点在于它实现了数据爬取和可视化分析，能够自动获取多页的数据并进行图表展示。

四、总结体会

通过这个项目的实现，我收获了很多的知识，对于爬虫我有了新的认识。随着经济的发展，基金越来越火爆，基金知识和数据的也越来越受大家的关注。通过python爬虫对于基金数据的获取，利用Python的数据分析工具进行数据处理和可视化分析，更加让我们方便了解数据的变化。

通过这个项目，我获得了以下经验和体会：学习了如何构建一个完整的Python爬虫系统，从需求分析到功能设计，再到实际实现。深入了解了HTTP请求和HTML解析的原理，以及如何处理反爬虫机制。掌握了数据存储和数据库操作的技能，为数据分析提供了基础。锻炼了项目管理和协作的能力，确保团队的合作和项目的顺利进行。同时，通过这次项目的实现，我对于python有了更加深入的了解和认识，对于python也有了浓厚的兴趣，对于在之后的python学习中更加有目标。