

学号： 2106410118



沈阳建筑大学

大数据技术基础 综合设计报告

2023 年秋季学期

学 院： 计算机科学与工程学院

专业班级： 计算机 2101 班

姓 名： 肖皓哲

一、题目名称：Python 开发网站图片爬取软件设计与实现

二、分析与设计：


需求分析于功能设计:将指定网站的图片下载到本地并以.jpg 的格式保存,先确定要访问的网站用 request 发送请求,然后用正则表达式匹配图片链接和图片名,将其下载到本地

三、系统实现

1、程序实现：

```
import requests
import re
import os
url = "https://www.eso.org/public/images/"
headers = {
    "user-agent": "Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/118.0.0.0 Safari/537.36 Edg/118.0.2088.46"}
response = requests.get(url=url,headers=headers)
response.encoding = response.apparent_encoding
l = re.compile('src: \'(.*)\'') # 图片链接
imagelink = re.findall(l,response.text)
n=re.compile('title: \'(.*)\'') #图片名字
imagename = re.findall(n,response.text)
file= "图片获取"
if not os.path.isdir(file):
    os.mkdir(file) # 创建文件
t=dict(zip(imagelink,imagename))
for x,y in t.items():
    try:
        with open(file+"/{0}.jpg".format(y),"wb") as img:
            res = requests.get("https://www.eso.org"+x)
            img.write(res.content) # 将图片请求的结果写到文件中
            img.close() # 关闭操作
        print(y+".jpg 图片获取成功 ..... ")
    except OSError:
        print(y+".jpg 图片获取失败")
```

2、运行与测试。



3、难点和亮点。

此程序的目的是从网站下载图像。使用请求库将 HTTP 请求发送到指定的 URL。然后，它使用正则表达式从响应中提取图像链接和名称。

主要亮点如下：

设置用户代理：将标头中的用户代理设置为模拟 Web 浏览器，这对于阻止来自非浏览器用户代理的请求的网站非常有用。

提取图像链接和名称：使用正则表达式从响应中提取图像链接和名称。它编译链接和名称的正则表达式模式，然后使用 `findall()` 方法查找响应文本中出现的所有模式。

创建文件夹：脚本检查名为“图片获取”的文件夹是否存在。如果没有，它将使用 `os.mkdir()` 方法创建文件夹。

下载图像：使用 `zip()` 函数遍历图像链接和名称。然后，它打开一个具有图像名称的文件，并使用 `write()` 方法将图像请求的内容写入该文件。最后，它为每个图像打印成功或失败消息。

错误处理：使用 `try-except` 块来处理映像下载过程中可能发生的任何异常。如果发生异常，它将打印该图像的失败消息。

难点：

正则匹配：在进行正则匹配时要获取的字符串中含有单引号，会使程序发生错误，当时为了处理这个问题在网上查阅相关资料后发现可以在单引号前加一个 `\` 来避免错误出现

处理图像请求：程序需要发出 HTTP 请求才能下载图像。它使用请求库发送请求，并检索响应的内容以写入图像文件。它还处理请求过程中可能发生的任何错误。

四、总结体会

在这次设计中我遇到了许多问题和错误，在网上查找了解决方法后，我对 python 语言有了更深的理解，我不仅对使用正则表达式、文件处理和 HTTP 请求更加熟练，还学会了错误处理和异常处理。这些技能在实际的编程工作中非常有用，尤其是在处理网络数据和文件时。我相信这些经验会对我的未来编程项目有很大的帮助。