

学号： 2106410123



沈阳建筑大学

大数据技术基础 综合设计报告

2023 年秋季学期

学 院： 计算机科学与工程学院
专业班级： 计算机 2101 班
姓 名： 施凯宸

正文格式：中文宋体、英文数字 Times New Roman、小四、单倍行距。

一、题目名称：Python 开发 XXX 软件设计与实现

二、分析与设计：

1、需求分析。

2、功能设计。

三、系统实现

1、程序实现。

2、运行与测试。

3、难点和亮点。

四、总结体会

结课考试后交报告电子版、打印版(总字数不少于 1000 字,建议双面打印),可以有少量代码,但不能连续 2 页或超过 2 页都是代码。可以小组合作完成,但报告必须一人一份,且在报告中说明个人独立完成的部分。小组人数不超过 2 人。

[电子版发 email 至 9455@sohu.com。](mailto:9455@sohu.com)

一、题目名称：Python 爬取爱奇艺热播榜并实现可视化

二、分析与设计：

1、需求分析。

热度第一的电影不一定是最好的电影 要结合弹幕量实现可视化的选出最优的电影

2、功能设计。

可以查看：排名, 电影名, 弹幕数, 近况, 简介, 热度

然后实现可视化比=比较排名和热度

三、系统实现

1、程序实现。

#导入模块 俩第三方库

```
import requests
```

```
from lxml import etree
```

```
import pandas as pd
```

```
import numpy as np
```

```
import matplotlib.pyplot as plt#导入matplotlib.pyplot
```

```
from matplotlib import font_manager
```

设置中文字体

```
plt.rcParams['font.family'] = 'SimHei'
```

如果需要显示负号, 请添加这行代码

```
plt.rcParams['axes.unicode_minus'] = False
```

#发起网络亲求

```
url="https://www.iqiyi.com/ranks1/1/0"
```

```
headers={'User-Agent':#headers 是字典
```

```
'Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36  
(KHTML, like Gecko) Chrome/118.0.0.0 Safari/537.36 Edg/118.0.2088.46' }
```

```
res=requests.get(url=url,headers=headers)#发起请求
```

```
print(res.status_code) #发送请求
```

```
def get_first_text(List):
```

```
    try:
```

```
        return List[0].strip()
```

```
    except:
```

```
        return "暂无消息"
```

```
html=etree.HTML(res.text)#封装
```

```
Lis=html.xpath('//*[@id="__layout"]/div/div[3]/div[2]/div[2]/div
```

```

/div[1]/a')#看有多少个打印长度
    print(len(Lis))
    count=1
    names=[]
    Danmu=[]
    Redu=[]
    for li in Lis:
        title= get_first_text(li.xpath('./div[2]/div[1]/text()')) #.
        代表当前的位置 大标题
        names.append(title)

    danmu=get_first_text(li.xpath('./div[2]/div[2]/span[2]/text()'))
        Danmu.append(danmu)

    jinkuang=get_first_text(li.xpath('./div[2]/div[2]/span[5]/text()'))
        jianjie=get_first_text(li.xpath('./div[2]/p/text()'))
        redu=get_first_text(li.xpath('./div[3]/div/span/text()'))
        Redu.append(int(redu))
        print("排名:",count,"电影名:",title,"弹幕数:",danmu,"近
        况:",jinkuang,"简介:",jianjie,"热度:",redu)
        count+=1


#使用 matplotlib 绘制图形
values = [0] * len(names)
plt.xticks(rotation=45)
plt.xlim(-2,25)


# 创建柱状图
plt.bar(names, Danmu)
# 设置两个图之间的纵向间隔
plt.subplots_adjust(hspace=0.5)
# 添加标题和标签
plt.title('电影评论热度')
plt.xlabel('电影名称')
plt.ylabel('弹幕数')

```

2、运行与测试。

排名: 1 电影名: 我经过风暴 弹幕数: 2.4万条弹幕 近况: 新增评论超2000 简介: 看似强势独立的徐敏有着难以启齿的秘密: 她被丈夫陈均长期家暴。徐敏不是所有人想象中受害者的模样, 她坚毅勇敢且有自己的事业, 在与律师李小萌艰难抗争试图离婚的过程中, 面对小心谨慎不留证据的丈夫、周遭人冷言冷语嘲讽质疑、社会系统的不作为、为了两个孩子...当离婚不是家暴的终点, 当家不是避风港而是暴雨本身, 她究竟能否冲破这场风暴? 热度: 6596

排名: 2 电影名: 学爸 弹幕数: 6.9万条弹幕 近况: 本周上新 简介: 雷大力为了让儿子雷小米能够拥有更高的人生起点, 在单亲妈妈刘真真的带领下, 被迫卷入了“幼升小”的激烈角逐。又在火哥和火嫂的影响下, 不惜倾尽所有购入学区房, 重重压力让父子二人的生活变得不堪一击。雷小米小姨的出现, 又让雷大力领悟了“拼娃”的本质是“拼父母”.....面对残酷的现实, 父子的生活困境应该如何破局? 几组家庭又将做出怎样的人生抉择? 热度: 6477

排名: 3 电影名: 长安三万里 弹幕数: 54.4万条弹幕 近况: 暂无消息 简介: 安史之乱爆发后数年, 吐蕃大军攻打西南。大唐节度使高适交战不利, 长安岌岌可危。困守孤城的高适向监军太尉回忆自己与李白的一生往事。 热度: 5133

排名: 4 电影名: 穷兄富弟 弹幕数: 6.6万条弹幕 近况: 暂无消息 简介: 《穷兄富弟》讲述身患尿毒症的司机王有财, 意外结识患有先天心脏病家境优越的富二代李致远, 二人意外配型相符签署“生死协议”。为成全王有财的遗愿, 李致远带着王有财给妻子相亲, 王有财也鼓励李致远去见自己的初恋, 人生最后的疯狂, 有笑有泪, 二人相互扶持着走完人生最后旅程的故事。 热度: 4630



排名: 5 电影名: 封神第一部: 朝歌风云 弹幕数: 13.8万条弹幕 近况: 暂无消息 简介: 商王殷寿与狐妖姬己勾结, 暴虐无道, 引发天谴。昆仑仙人姜子牙携“封神榜”下山, 寻找天下共主, 以救苍生。西伯侯之子姬发逐渐发现殷寿的本来面目, 反出朝歌..... 热度: 4576

排名: 6 电影名: 巨齿鲨2: 深渊 弹幕数: 10万条弹幕 近况: 暂无消息 简介: 海洋霸主巨齿鲨, 今夏再掀狂澜! 乔纳斯·泰勒与科学家张九溟双雄联手, 进入海底7000米深渊执行探索任务。他们意外遭遇史前巨兽海洋霸主巨齿鲨群的攻击, 还将对战凶猛危险的远古怪兽群。惊心动魄的深渊冒险, 巨齿巨爽的深海大战一触即发..... 热度: 4460

排名: 7 电影名: 绝地追击 弹幕数: 13.3万条弹幕 近况: 暂无消息 简介: 首度揭秘边境最大势力的武装毒贩, 九十年代末我国西南边境, “8077”边防武警特战队在一次剿毒任务中, 先后遭遇山洪灾难和毒贩的算计, 死伤惨重。为了牺牲的兄弟, “8077”幸存战士誓死展开绝地追击。 热度: 4389

排名: 8 电影名: 燃冬 弹幕数: 5.5万条弹幕 近况: 暂无消息 简介: 延吉是中国北方边境的一个小镇, 从上海来参加婚礼的浩丰感到有些迷茫。一次偶然的机会, 他遇到了娜娜, 一个让他着迷的年轻导游。她把他介绍给一个厨师朋友韩萧, 他们三个人很快就因为韩萧的一顿饭而结下了友谊。这次热烈的接触使他们面对自己的过去和秘密, 他们沉睡的欲望慢慢解开, 就像长白山的风景和雪林一样。 热度: 3936

排名: 9 电影名: 章贡 弹幕数: 1.2万条弹幕 近况: 本周上新 简介: 影片讲述了范静雅为了儿子致力于研究治疗渐冻症的医学方案, 被陈老板利用研制出变异高智商章贡, 带



3、难点和亮点

难点：弹幕数量是字符串，需要写一个专门判断的 弹幕有过万的也有没过万的 这个字符串判断是很麻烦的 必须得保证数据质量和一致性：在爬取电影数据时，我遇到了错误、缺失、重复或不一致的数据，有些位置数据是空的，会报错，我得先写一个判空的程序，但这还是最容易发现的问题，但大量的数据我无法检测出数据的正确性。

四、总结体会

首先 我先去网上学习了解如何爬取豆瓣电影，然后经过思考，和尝试 发现有一些网站是有反爬虫机制：许多网站采用反爬虫技术来限制对其数据的访问。还发现有些网站爬取到的代码是乱码，查询了原因发现可能是，用的码不一样，得需要翻译，但我还是没能解决。随后还是尝试爬取电影之类的网站，发现爱奇艺是可行的，之后就是结合上课所学的可视化的知识，把电影名和热度还有电影名和弹幕量形成了可视化，可以通过寻找弹幕第一和和热度第一来找出真正的好电影。这次爬取并没有考虑到数据的法律和道德问题：在爬取电影数据时，我需要遵守相关法律法规和道德准则，确保我有权利爬取目标网站上的信息，并遵循网络爬虫的行为准则。