

学号： 2108620101



沈阳建筑大学

大数据技术基础 综合设计报告

2023 年秋季学期

学 院： 计算机科学与工程学院

专业班级： 计算机 2101 班

姓 名： 马银龙

链家网国内二手房信息综合设计报告

—基于 python 爬虫技术

一、分析与设计：

1、需求分析。

随着国民日益增长的买房需求，同房价居高不下的对比，二手房市场迎来了春天。本此设计通过爬取链家网上国内的二手房信息，通过数据可视化，多方面多角度对比了二手房的价格同区位、朝向、装修之间的关系，通过数据可视化可以满足人们对自己购房的各种需求同时也可以兼顾价位，真正做到为人民提供便利的需求。在细节部分，我将爬取到的二手房信息保存到了 Excel 文件中，生成了各种分析图，更加直观的分析房价信息。

2、功能设计。

(1)技术栈选择：

- 1、Request 用于发送 HTTP 请求。
- 2、parsel 用于解析 HTML 页面。
- 3、Csv 用于将数据存储到 csv 文件中。
- 4、Matplotlib 用于绘制图表，本设计内创建了直方图、核密度估计图、饼图、柱状图、箱图，并且使用其中的 plt.rcParams。
- 5、Pandas 导入 csv 文件来进行数据处理，分类和聚合，为绘图提供数据。
- 6、Numpy 用于数值计算的 python 这里是为 Pandas 和 Matplotlib 提供基础。

(2)爬虫架构设计：

- 1、爬虫引擎负责控制整个爬虫流程，包括 URL 管理、请求发送和数据提取。
- 2、数据提取模块使用 Xpath 从网页中提取所需要的信息。
- 3、数据存储模块将提取的数据保存在 csv 文件中。
- 4、使用 User-Agent 和 IP 代理池实施反爬虫策略。

(3)数据可视化：

将获取的数据进行去重、排序和持久化，保存到 Excel 文件中。读取 Excel 文件，其中使用 selector 选择器从网页中捕获所需要的信息。

价格分布分析六图：

- 1、价格的直方图，展示了二手房价格的分布情况。通过直方图，可以清晰地看到价格的分布情况。
- 2、价格分布的核密度估计曲线，以更清晰地了解价格分布的概率密度。这有助于识别价格分布的主要模式。
- 3、饼图分析了不同装修和朝向类型的二手房数量占比。这有助于理解不同装修和朝向的二手房分布情况。
- 4、装修类型与房价的关系图，展示了不同装修类型的平均价格以及价格的标准差。这使你可以比较不同装修类型的价格差异。
- 5、朝向与房价的关系图，展示了不同朝向的平均价格以及价格的标准差。这有助于分析不同朝向对价格的影响。
- 6、箱线图，显示了不同朝向的二手房价格分布情况。这提供了对价格分布的更详细的了解。

三、系统实现

1、程序实现。

(1)爬虫功能的实现：

```
import requests
import parsel
import csv
import time

# 以a的方式创建或者写一个csv文件并且newline的指定方式是""
f = open('沈阳市二手房售房信息9.csv', mode='a', encoding='utf_8_sig', newline='')
# 调用csv.DictWriter() 返回一个DictWriter对象然后调用 writeheader() 函数写入csv文件第一行
csv_write = csv.DictWriter(f, fieldnames=['标题', '地址', '户型', '面积', '朝向', '装修', '楼层', '年代', '关注及发布', '其它', '总价(万)', '单价(元/平)', '详情'])
csv_write.writeheader()
web_list = ['shenhe', 'hunnan', 'tiexi', 'heping', 'dadong', 'huanggu', 'yuhong', 'shenbeixinqu']
name_list = ['沈河区二手房', '浑南区二手房', '铁西区二手房', '和平区二手房', '大东区二手房', '浑南区二手房', '于洪区二手房', '沈北新区二手房']
# 对url地址进行分析，爬取Lianjia网沈阳浑南区的房产二手房数据
for i in range(0, len(web_list)):
    for page in range(1, 2):
        # 爬取每页返回三页
        # time.sleep(1)
        # city=input("请输入要查询的城市 eg(沈阳 请输入sy)//控制台输入输出版本
        # area=input("请输入所要查询的市区 eg(浑南区 请输入hunnan)")

        print(f'=====正在爬取{name_list[i]+'第'+str(page)+''}页数据内容=====')
        # 此处可以进行字符串拼接可以实现全国二手房价的爬取，要实现全国房价的爬取只需要将city与area拼接到url中即可
        url = f'https://sjc.lianjia.com/ershoufang/{web_list[i]}/pg{page}/'
        headers = {
            'User-Agent': 'Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/118.0.0.0 Safari/537.36'
        }
        response = requests.get(url=url, headers=headers)
        # print(response.text)
        selector = parsel.Selector(response.text)
        divs = selector.css('div.info.clear')
        # print(divs)
        for div in divs:
            title = div.css('.title a::text').get()
            area_list = div.css('.positionInfo a::text').getall()
            area = ' '.join(area_list)
            house_info = div.css('.houseInfo::text').get().split('|')
            house_type = house_info[0]
            house_area = house_info[1]
            house_face = house_info[2]
            decoration = house_info[3]
```

```

35     divs = selector.css('div.info.clear')
36     # print(divs)
37     for div in divs:
38         title = div.css('.title a::text').get()
39         area_list = div.css('.positionInfo a::text').getall()
40         area = '-'.join(area_list)
41         house_info = div.css('.houseInfo::text').get().split('|')
42         house_type = house_info[0]
43         house_area = house_info[1]
44         house_face = house_info[2]
45         decoration = house_info[3]
46         floor = house_info[4]
47         years = house_info[5]
48         follow_info = div.css('.followInfo::text').get().replace(' / ', ',')
49         tag_list = div.css('.tag span::text').getall()
50         tag = '|'.join(tag_list)
51         totalprice = div.css('.totalPrice span::text').get()
52         unitprice = div.css('.unitPrice span::text').get().replace('元/平','')
53         href = div.css('.title a::attr(href)').get()
54         dit = {
55             '标题': title,
56             '地址': area,
57             '户型': house_type,
58             '面积': house_area,
59             '朝向': house_face,
60             '装修': decoration,
61             '楼层': floor,
62             '年代': years,
63             '关注及发布': follow_info,
64             '其它': tag,
65             '总价(万)': totalprice,
66             '单价(元/平)': unitprice,
67             '详情': href,
68         }
69     }
70     csv_write.writerow(dit)
71     print(title, area, house_type, house_area, house_face, decoration, floor, years, follow_info, tag, totalprice+"万",
72           unitprice, href, sep='|')
73     print(name_list[i]+"爬取完毕! \n\n")
74

```

(2) 数据分析代码:

```

import matplotlib.pyplot as plt
import pandas as pd
import numpy as np
plt.rcParams['font.sans-serif']=['SimHei']
plt.rcParams['axes.unicode_minus'] = False
data=pd.read_csv(r'C:\Users\Admin\Desktop\python综合设计\沈阳市二手房售房信息8.csv')
data['总价(万)'].plot(kind='hist',bins=10,density=True,title='shenyang_second-hand house')
data['总价(万)'].plot(kind='kde',style='r')
plt.xlabel('房价')

plt.ylabel('Density')
plt.show()

dec=data.groupby(['装修'])['装修'].count()
fun = data.groupby(['朝向'])['朝向'].count()
fig = plt.figure(figsize = (20,20))
fig.add_subplot(2,2,1)
dec.plot(kind = 'pie',title = 'dec',startangle = 60,autopct = '%1.1f%%')
fig.add_subplot(2,2,3)
fun.plot(kind = 'pie',title = 'function',startangle = 1000,autopct = '%1.1f%%')
plt.savefig('饼图.jpg',dpi = 1000,bbox_inches = 'tight')

plt.show()

mean = data.groupby(['装修']).agg({'总价(万)':np.mean})
std = data.groupby(['装修']).agg({'总价(万)':np.std})
mean.plot(kind = 'bar',yerr = std ,rot = 40,title = 'Decoration and housing prices',legend = False,color = 'r')
plt.xlabel('装修方式')
plt.ylabel('房价')
plt.show()

```

```

mean = data.groupby(['装修']).agg({'总价(万)':np.mean})
std = data.groupby(['装修']).agg({'总价(万)':np.std})
mean.plot(kind = 'bar',yerr = std ,rot = 40,title = 'Decoration and housing prices',legend = False,color = 'r')
plt.xlabel('装修方式')
plt.ylabel('房价')
plt.show()

mean = data.groupby(['朝向']).agg({'总价(万)':np.mean})
std = data.groupby(['朝向']).agg({'总价(万)':np.std})
mean.plot(kind = 'bar',yerr = std ,rot = 40,title = 'Decoration and housing prices',legend = False,color = 'y')
plt.xlabel('朝向')
plt.ylabel('房价')
plt.show()


data[['总价(万)', '朝向']].boxplot(by = '朝向',figsize = (15,10))
plt.show()




```

3、运行与测试

(1) 图形的显示

饼图：





(2) 在文件所在地址生成相应的 Excel 表

 2108620101-马银龙-大数据上机报告.d...	2023/10/18 15:47	DOCX 文档	409 KB
 饼图.jpg	2023/10/18 19:47	JPG 图片文件	2,240 KB
 沈阳市二手房.py	2023/10/18 19:47	Python 源文件	4 KB
 沈阳市二手房售房信息.csv	2023/10/14 20:11	XLS 工作表	63 KB
 沈阳市二手房售房信息1.csv	2023/10/17 11:44	XLS 工作表	0 KB
 沈阳市二手房售房信息8.csv	2023/10/17 19:45	XLS 工作表	56 KB
 沈阳市二手房售房信息9.csv	2023/10/18 16:44	XLS 工作表	55 KB
 沈阳市二手房数据分析.py	2023/10/17 20:59	Python 源文件	2 KB

(3) 控制台输出展示

```
In [1]: runfile('C:/Users/Admin/Desktop/python综合设计/沈阳市二手房.py', wdir='C:/Users/Admin/Desktop/python综合设计')
=====正在爬取沈河区二手房第{1}页数据内容=====
越秀二期四室两卫带家政间精装交付看园区主景观拎包入住|越秀星汇云锦(二期) -东五里河|4室1厅 | 151.87平米 | 南 北 | 精装 | 中楼层(共33层) | 2021年建 |0人关注,8天以前发布|VR房源|随时看房|339万|22,322|https://sy.lianjia.com/ershoufang/102107317715.html
沈水小区4楼 南北通透 户型好不把山不临街采光好|沈水小区 -南塔|2室1厅 | 82.23平米 | 南 北 | 简装 | 中楼层(共7层) | 2000年建 |1人关注,7天以前发布|VR看装修|房本满五年|随时看房|53.8万|6,543|https://sy.lianjia.com/ershoufang/102107325896.html
新一楼北站 惠工夜市 市府广场 配套齐全 交通便利|望远社区 -金融中心|2室2厅 | 131.39平米 | 南 北 | 简装 | 低楼层(共6层) | 1998年建 |2人关注,25天以前发布|近地铁|VR房源|房本满五年|85万|6,470|https://sy.lianjia.com/ershoufang/102107263517.html
龙净都市阳光精装两居南北通透近地铁|龙净都市阳光 -新立堡|2室1厅 | 69.77平米 | 南 北 | 精装 | 中楼层(共11层) | 板楼|0人关注,11天以前发布|VR看装修|房本满五年|随时看房|56万|8,027|https://sy.lianjia.com/ershoufang/102107303809.html
越秀星汇云锦二期,前排 四室 精装 不挡光 拎包入住。|越秀星汇云锦(二期) -东五里河|4室2厅 | 162.43平米 | 南 北 | 精装 | 中楼层(共17层) | 2021年建 |0人关注,6个月以前发布|VR看装修|随时看房|388万|23,888|https://sy.lianjia.com/ershoufang/102106528324.html
阳光社区,五爱商圈,繁华,出行购物便利|阳光社区 -五爱|2室1厅 | 55平米 | 东 | 其他 | 高楼层(共7层) | 1995年建 |0人关注,27天以前发布|VR看装修|房本满五年|随时看房|18万|3,273|https://sy.lianjia.com/ershoufang/102107256544.html
青年大街 市图书馆 河畔花园 园区好位置 采光充足|河畔花园 -金廊|4室2厅 | 221.16平米 | 南 北 | 简装 | 中楼层(共5层) | 2005年建 |10人关注,4个月以前发布|近地铁|VR房源|房本满五年|随时看房|150万|6,783|https://sy.lianjia.com/ershoufang/102106867049.html
D王 国际花园轻奢 精装修 业主诚心出售,价格能研究!|地王国际花园 -金廊|3室2厅 | 132.19平米 | 南 北 | 精装 | 低楼层(共31层) | 2005年建 |0人关注,15天以前发布|近地铁|VR看装修|房本满五年|245万|18,534|https://sy.lianjia.com/ershoufang/102107289703.html
中金启城南区步梯中间楼层,简单装修 诚心出售|中金启城南区 -新立堡|3室1厅 | 97.96平米 | 南 北 | 简装 | 中楼层(共6层) | 板楼|0人关注,23天以前发布|VR房源|房本满五年|136万|13,884|https://sy.lianjia.com/ershoufang/102107271912.html
保利海上五月花二期,南北通透,满五唯一|保利海上五月花二期 -新立堡|2室2厅 | 93.97平米 | 南 北 | 精装 | 中楼层(共5层) | 板楼|0人关注,25天以前发布|VR看装修|房本满五年|100万|10,642|https://sy.lianjia.com/ershoufang/102107263372.html
中房上东花墅7.1期 婚装 多层中间层|中房上东花墅 -新立堡|2室2厅 | 81.32平米 | 南 北 | 其他 | 中楼层(共6层) | 板楼|0人关注,15天以前发布|VR看装修|房本满五年|83万|10,207|https://sy.lianjia.com/ershoufang/102107291198.html
五爱社区顺通小区 5楼南北两室 不把山不临街|顺通社区 -金廊|2室0厅 | 46.62平米 | 南 北 | 其他 | 中楼层(共8层) | 1995年建 |0人关注,14天以前发布|近地铁|VR看装修|房本满五年|67万|12,204|https://sy.lianjia.com/ershoufang/102107303205.html
```

4、难点和亮点。

难点:

- 1、网页结构变化:网站的 HTML 结构可能随时变化,这可能会影响到数据提取部分的代码。因此,需要定期检查和更新代码以适应潜在的结构变化。
- 2、异常处理:代码中没有包括异常处理,如处理网络请求失败、页面加载

超时等情况的代码。在实际应用中，应该添加适当的异常处理来提高代码的健壮性。

亮点：

- 1、数据提取：使用 Parsel 库和 XPath 选择器来提取页面中的各种信息，如标题、地址、户型等。这是非常高效和准确的方法。
- 2、反爬虫策略：代码包括了一些反爬虫策略，如设置 User-Agent，以减少被网站封禁的风险。这是在爬虫开发中非常重要的一部分。
- 3、数据写入：通过使用 csv.DictWriter 将爬取的数据写入 CSV 文件，保持数据的结构化和易于分析。
- 4、迭代不同区域：你的代码循环遍历不同区域的二手房信息，这使得你可以获取多个地区的数据。

四、总结体会

通过本次 python 综合设计，我学会了 python 爬取网页信息的一些手段和反扒技术，通过 selector 选择器从网页中根据标签的属性选择要爬取的内容，通过爬虫一些固有的模板结合一些实际的网页情况，成功的爬取到了以沈阳市为代表的链家全国二手房信息，并且结合了课上数据分析的一些知识和 python 库函数成功的做出了爬取信息的图表可视化。与此同时，数据可视化和分析提供了对沈阳市二手房价格数据的有用见解。这些图表和分析可以帮助买家、卖家和投资者更好地理解市场情况，做出明智的决策。

总之，通过这次大数据综合设计我受益匪浅。