

KNN 算法

一、KNN 概述

kNN(k-nearest neighbors) K-近邻:

KNN 是比较经典的算法，属于机器学习算法中最简单、最基本、相对比较容易理解的算法，是十大机器算法之一。

kNN 算法的指导思想是“近朱者赤，近墨者黑”，根据待分类样本周围的已知类别样本来判断待分类样本的类别，即由你的邻居来推断出你的类别。

1、简单说，如果你周围都是猴子，那 kNN 就认为你是猴子，如果你周围都是大学生，那 kNN 就认为你是大学生。


2、我们常常听到一个故事：如果要了解一个人的经济水平，只需要知道他最好的 5 个朋友的经济能力，对他的这五个人的经济水平求平均就是这个人的经济水平。这句话里面就包含着 kNN 的算法思想。

3、此外，电影按照题材分类也是 KNN 算法的应用，如判定某部电影属于某个题材呢？同一题材的电影具有那些公共特征？这是需要在分类电影时考虑的问题。

那么动作片具有哪些公共特征？又与爱情片存在哪些明显差别呢？动作片也存在亲吻镜头，爱情片也存在打斗镜头，所以不能单纯从是否存在打斗或者亲吻镜头来判断。但爱情片亲吻镜头比动作片多，同样动作片打斗镜头更多。这些可以基于电影中出现的亲吻、打斗次数，使用 kNN 算法来划分电影题材类型。

二、KNN 工作原理

kNN 算法通过测量不同特征值之间的距离来进行分类。下图进行简单说明：绿色的圆点就是预测实例，蓝色和红色元素就是训练集中不同的类。



当 $K=3$ 时（即图中黑色实线的圆），红色三角形出现 2 次，蓝色矩形出现 1 次，所以绿色圆实例与红色三角形属于同一类。

当 $K=5$ 时（即图中黑色虚线的圆），红色出现 2 次，而蓝色出现 3 次，所以绿色实例应该与蓝色矩形属于同一类。

1、涉及到的问题：

(1) 实例与实例之间的距离是怎么计算的？

(2) 当选取 K 不同的时候，相同的实例会有不同的分类结果，所以这个距离 K 是怎么选取的？

2、KNN 算法涉及 3 个主要因素：训练集、距离或相似度的衡量、k 的大小。

3、算法步骤：

(1) 算距离：存在一个已知类别的训练集（即每个数据都存在标签）。输入没有标签的新数据（测试对象），将新数据的每个特征与训练集每个数据对应的特征进行比较，计算距离；

(2) 找邻居：选择 k 个距离最近的训练对象，作为测试对象的近邻(k-近邻中 k 的出处)；

(3) 做分类：提取分类标签，选择 k 个最相似数据中出现次数最多的分类，作为新数据的分类。

步骤分解：

(1) 算距离：即距离或相似度的衡量

什么是合适的距离衡量？距离越近应该意味着这两个点属于一个分类的可能性越大。

对于两个向量 (x_i, x_j) ，一般使用 L_p 距离进行计算。假设特征空间 X 是 n 维实数向量空间 R^n ，其中， $x_i, x_j \in X$ 。


$$x_i = (x_i^{(1)}, x_i^{(2)}, \dots, x_i^{(n)}), x_j = (x_j^{(1)}, x_j^{(2)}, \dots, x_j^{(n)})$$

x_i, x_j 的 L_p 距离定义为：

$$L_p(x_i, x_j) = \left(\sum_{i=1}^n |x_i^{(i)} - x_j^{(i)}|^p \right)^{\frac{1}{p}}$$

这里的 $p \geq 1$ 。

当 $p=2$ 时候，称为欧氏距离(Euclidean distance)，即：欧氏距离就是我们生活中所说的两点之间的最短距离，而曼哈顿距离就是两点之间每个维度的距离之和，用下图解释：



如图，在二维坐标中，两个黑点之间绿色的线就是欧氏距离；而红色、蓝色、黄色的折线都是等长的，就是曼哈顿距离。用到多维坐标中也是如此。

$$L_2(x_i, x_j) = \left(\sum_{i=1}^n |x_i^{(i)} - x_j^{(i)}|^2 \right)^{\frac{1}{2}} \text{ 或写成}$$

$$d(x, y) = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2 + (x_3 - y_3)^2 + \dots + (x_n - y_n)^2} = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

缺点：它将样本的不同属性（即各指标或各变量量纲）之间的差别等同看待，这一点有时不能满足实际要求。比如年龄和学历对工资的影响，将年龄和学历同等看待；收入单位为元和收入单位为万元同等看待。

解决办法：标准化欧式距离，将属性进行标准化处理，区间设置在[0,1]之间，减少量纲的影响。

当 $p=1$ 时候, 称为曼哈顿距离(Manhattan distance), 即:

$$L_1(x_i, x_j) = \sum_{l=1}^n |x_i^{(l)} - x_j^{(l)}| \text{ 或写成 } d_{12} = |x_{11} - x_{21}| + |x_{12} - x_{22}| + |x_{13} - x_{23}| + \dots + |x_{1k} - x_{2k}| = \sum_{k=1} |x_{1k} - x_{2k}|$$

当 $p=\infty$ 时候, 称为极大距离(infty distance), 表示各个坐标的距离最大值, 即:

$$L_p(x_i, x_j) = \max_l |x_i^{(l)} - x_j^{(l)}|$$


另外也包含夹角余弦等方法。一般采用欧式距离较多, 但是文本分类则倾向于使用余弦来计算相似度。

(2) 找邻居: (解答问题二)

kNN 中的 k 是一个超参数, 是算法的核心, 需要进行指定, 一般情况下这个 k 和数据有很大关系, 寻找 K 值的方法叫做交叉验证法。

交叉验证法: 对于较小的数据集, 程序自己按一定规则尝试多个 k 值, 对每一个 k , 记录其在验证集上的错误次数, 取错误数最小的 k 。

一般 K 从 3 开始, 然后取每个 K 都遍历训练集, 寻找 K 为何值时, 预测的准确度最高。建议使用交叉验证时, $k \in [2, 20]$, 使用交叉验证即可得到一个很好的 k 值。但是不是说, K 越小越好? 当然不是, 把上图改造后, 如下图所示:



现在假定绿色和红色属于一类, 那么如果当 $K=1$ (橙色圈) 或 6 (黑色虚线圈) 时, 这个算法会把绿色和蓝色归为一类, 而当 $K=3$ 时, 才是正确的结果。把 $K=1$ 时选取的那个蓝色实例称为训练集中的噪声, 应当避免这种干扰项。而 $K=6$ 时, 距离较远的实例也会算进来, 干扰了预测。所以选取适当的 K 的值是十分必要的。

因此, kNN 中 k 的取值非常重要, 选择最优 k 值是建立一个合理、精确的 kNN 模型的必要条件。

- 1) 如果 k 值太低, 则模型会变得过于具体, 容易受到个例影响, 不能很好地泛化。它对噪音也很敏感。该模型在训练组上实现了很高的精度, 但对于新的、以前看不到的数据点, 该模型的预测能力较差。即 k 值可以表示模型复杂度, 当 k 值越小意味着模型复杂度变大, 更容易得到一个过拟合的模型(用极少数的样例来决定这个预测的

结果，很容易产生偏见，这就是过拟合)。

- 2) 如果 k 选择得太大，模型就会变得过于泛化，不能很好的体现 Nearest，无法准确预测训练和测试集中的数据点。这种情况被称为欠拟合。即 k 值越多学习的估计误差越小，但是学习的近似误差就会增大。

(3) 做分类：即类别的判定

KNN 是一种有监督的机器学习算法，主要思想是投票机制，可用于解决分类和回归问题。

KNN 的核心数学知识是距离的计算和权重的计算。把需要预测的点作为中心点，然后计算其周围一定半径内的已知点距其的距离，挑选前 k 个点，进行投票。根据多数表决原则确定数据点的类别。如果 k 设置为 5，则检查 5 个最近点的类别。也可以根据多数类进行回归预测，同样，KNN 回归取 5 个最近点的平均值。

即分类问题则进行表决投票，回归问题使用加权平均或者直接平均的方法。

投票决定：少数服从多数，这 k 个点中，哪个类别的点多，该预测点就被判定属于哪一类。

加权投票法：根据距离的远近，对近邻的投票进行加权，距离越近则权重越大（权重为距离平方的倒数）

*权重：指某一个因素相对于整个事物的重要程度，它既体现了各个因素所占的百分比，同时也强调了因素的相对重要程度和贡献度。

例如，成绩评分分为平时成绩和考试成绩，平时成绩占总成绩的 30%，而考试成绩占 70%。也就是说，如果平时成绩是 90 分，考试成绩是 80 分，则总成绩是 $90 \times 0.3 + 80 \times 0.7 = 83$ 分。从这个权重配比来看，相比平时成绩，学校更看重的是考试成绩。

4、用 k 近邻算法实现回归任务

分类模型和回归模型本质一样，分类模型是将回归模型的输出离散化。

一般来说，回归问题通常是用来预测一个值，如预测房价、未来的天气情况等等，例如一个产品的实际价格为 500 元，通过回归分析预测值为 499 元，我们认为这是一个比较好的回归分析。回归是对真实值的一种逼近预测。

分类问题是用于将事物打上一个标签，通常结果为离散值。例如判断一幅图片上的动物是一只猫还是一只狗。分类并没有逼近的概念，最终正确结果只有一个，错误的就是错误的，不会有相近的概念。

简言之：

定量输出称为回归，或者说是连续变量预测，预测明天的气温是多少度，这是一个回归任务。

定性输出称为分类，或者说是离散变量预测，预测明天是阴、晴还是雨，就是一个分类任务。

前面介绍了如何用 k 近邻算法实现分类任务，接下来简述如何用 k 近邻算法实现回归任务。

最常用的 K 近邻算法回归模型是将离待预测样本点最近的 k 个训练样本的平均值

作为待预测样本点的结果输出。

比如我们想销售一款蛋糕，刚开始不知道定价多少，于是打听了离我们最近的三家蛋糕店（ $k=3$ ）的价格，他们卖价分别为 35 元、45 元、40 元，所以我们最终定价为这三家店的均值，即 $(35+45+40)/3=40$ 元，这就是用 k 近邻算法来帮我们预测蛋糕价格的问题。

三、优缺点

1、优点：

简单，易于理解，易于实现，无需估计参数，无需训练；适合对稀有事件进行分类，特别适合于多分类问题(multi-modal，对象具有多个类别标签)，例如根据基因特征来判断其功能分类， kNN 比 SVM 的表现要好。

2、缺点：

懒惰算法，对测试样本分类时的计算量大，内存开销大，评分慢；
可解释性较差，无法给出决策树那样的规则。

四、常见问题

1、 k 值设定为多大？

k 太小，分类结果易受噪声点影响； k 太大，近邻中又可能包含太多的其它类别的点。

（对距离加权，可以降低 k 值设定的影响）

k 值通常是采用交叉检验来确定（以 $k=1$ 为基准）

经验规则： k 一般低于训练样本数的平方根

2、类别如何判定最合适？

投票法没有考虑近邻的距离的远近，距离更近的近邻也许更应该决定最终的分类，所以加权投票法更恰当一些。

3、如何选择合适的距离衡量？

高维度对距离衡量的影响：众所周知当变量数越多，欧式距离的区分能力就越差。

变量值域对距离的影响：值域越大的变量常常会在距离计算中占据主导作用，因此应先对变量进行标准化。

4、训练样本是否要一视同仁？

在训练集中，有些样本可能是更值得依赖的。

可以给不同的样本施加不同的权重，加强依赖样本的权重，降低不可信赖样本的影响。

5、性能问题？

kNN 是一种懒惰算法，平时不好好学习，考试（对测试样本分类）时才临阵磨枪（临时去找 k 个近邻）。

懒惰的后果：构造模型很简单，但在对测试样本分类时的系统开销大，因为要扫描全部训练样本并计算距离。

已经有一些方法提高计算的效率，例如压缩训练样本量等。

6、能否大幅减少训练样本量，同时又保持分类精度？

浓缩技术(condensing)

编辑技术(editing)