

机器学习

Machine Learning

(多领域交叉学科)

任 义

沈阳建筑大学 计算机学院



目录

CONTENTS

1

机器学习简介

2

机器学习相关基础知识

3

K近邻算法 (KNN)

4

线性回归法

5

主成分分析法 (PCA)

6

逻辑回归法

7

支持向量机算法 (SVM)

8

决策树算法

9

集成学习和随机森林

1

主成分分析法 (PCA)

方差

方差是指一组数据中的各个数减去这组数据的平均数的平方和的平均数。

例：(1 , 2 , 3 , 4 , 5)

平均数=3

各个数与平均数差的平方和=10

方差=2

方差用于测算数值型数据的离散程度。

协方差

协方差用于度量各个维度偏离其均值的程度。

协方差的计算方法 (以二维为例子) :

$$\text{cov}(X, Y) = E(x - \bar{x})(y - \bar{y})$$

其中 $\bar{x}$, $\bar{y}$ 表示均值。


协方差的结果有三种解释方式

当 $\text{cov}(X, Y) > 0$ 时, 表明 X 和 Y 正相关;


1

主成分分析法 (PCA)


当 $\text{cov}(X,Y)>0$ 时，表明X和Y正相关；



当 $\text{cov}(X,Y)<0$ 时，表明X和Y负相关；



当 $\text{cov}(X,Y)=0$ 时，表明X和Y不相关。



协方差为0，两个随机变量不一定相互独立，而两个随机变量相互独立，协方差一定为0。

维度灾难

简单的说就是变量的个数多，如果变量个数增加，随之需要估计的参数个数也在增加。

1

主成分分析法 (PCA)

主成分分析

- 一个非监督的机器学习算法
- 主要用于数据的降维
- 通过降维，可以发现更便于人类理解的特征
- 其他应用：可视化；去噪

176806485

1

主成分分析法 (PCA)




先看如何由二维降为一维，通常情况下，在2个特征中选择一个特征即可。



1

主成分分析法 (PCA)

先看如何由二维降为一维，通常情况下，在2个特征中选择一个特征即可。



1

主成分分析法 (PCA)



问题一：判断一下哪个方案是更好一些的方案呢？

若各点之间距离间距较大，即拥有更好的可区分度，是该方案为好一些的方案。

问题二：这是最好的方案吗？有没有比这种更好的方案呢？

1

主成分分析法（PCA）



方案三：将所有样本点映射到一个轴上，可理解为平面上的点用线上的点来表示，即二维用一维来表示，也达到了降维的目的。这种映射方案中，映射后的样本点和原来的样本点相比，并没有太大差距，更趋近于原来的分布情况，换句话说，点和点之间的距离与映射到坐标轴上的方案相比，更大一些。这样它们之间的区分度更加明显。

由此我们的问题，变为：如何找到让样本间间距最大的轴？→如何定义样本间间距？

1

主成分分析法 (PCA)


事实上，在统计学中，可以用方差 (Variance) 来表示样本间的间距。

方差是描述样本整体疏密程度的一个指标。方差越大表示样本间越稀疏，方差越小表示样本间越紧密。

方差公式：

$$Var(x) = \frac{1}{m} \sum_{i=1}^m (x_i - \bar{x})^2$$

(每一个样本减去样本的均值的平方和)




1

主成分分析法 (PCA)

第一步：将样例的均值归为0 (demean)

(所谓均值归0是指所有样本减去这些样本的均值)



这样可以使得样本每一个维度它的均值都是0

1

主成分分析法 (PCA)

公式推导：

$$Var(x) = \frac{1}{m} \sum_{i=1}^m (x_i - \bar{x})^2$$

$$Var(x) = \frac{1}{m} \sum_{i=1}^m x_i^2$$


$$\bar{x} = 0$$

(此处的 x_i 是指所有坐标点已经映射到新的坐标轴之后，得到的新的样本点)

1

主成分分析法 (PCA)

这个新的坐标轴在下图中坐标系中有两个维度，我们可用 w_1 和 w_2 表示：



1

主成分分析法 (PCA)

总结一下：

- 1、对所有样本进行demean处理
- 2、求出一个轴的方向 $w=(w1,w2)$
- 3、使得所有样本映射到 w 以后，有：

$$Var(X_{project}) = \frac{1}{m} \sum_{i=1}^m (X_{project}^{(i)} - \bar{X}_{project})^2$$

最大

1

主成分分析法 (PCA)

此处： $X_{project}$ 由多个维度构成的向量
可写成如下形式：

$$Var(X_{project}) = \frac{1}{m} \sum_{i=1}^m \|X_{project}^{(i)} - \bar{X}_{project}\|^2$$


即：

$$Var(X_{project}) = \frac{1}{m} \sum_{i=1}^m \|X_{project}^{(i)}\|^2 \quad \text{最大}$$

1

主成分分析法 (PCA)

现在推导如何用 $X^{(i)}$ 表示 $X_{project}^{(i)}$



$(X_{pr1}^{(i)}, X_{pr2}^{(i)})$

$w = (w_1, w_2)$

$X^{(i)} = (X_1^{(i)}, X_2^{(i)})$

$$X^{(i)} \cdot w = \|X^{(i)}\| \cdot \|w\| \cdot \cos \theta$$
$$X^{(i)} \cdot w = \|X^{(i)}\| \cdot \cos \theta$$
$$X^{(i)} \cdot w = \|X_{project}^{(i)}\|$$
$$Var(X_{project}) = \frac{1}{m} \sum_{i=1}^m \|X^{(i)} \cdot w\|^2 \quad \text{最大}$$

注：此处点乘的结果是一个数，所以两端的取模符号可不写。

1

主成分分析法 (PCA)

目标：求 w ，使得 $Var(X_{project}) = \frac{1}{m} \sum_{i=1}^m (X^{(i)} \cdot w)^2$ 最大



$$Var(X_{project}) = \frac{1}{m} \sum_{i=1}^m (X_1^{(i)} w_1 + X_2^{(i)} w_2 + \dots + X_n^{(i)} w_n)^2$$

$$Var(X_{project}) = \frac{1}{m} \sum_{i=1}^m \left(\sum_{j=1}^n X_j^{(i)} w_j \right)^2$$

一个目标函数的最优化问题，若求的是最大值，则可使用梯度上升法解决

1

主成分分析法（PCA）



PCA中横纵坐标是两个特征，线性回归中只有一个特征，是通过特征值找到相应的直线上的点，该点和输出标记的MSE最小，因此线性回归中，在二维平面上，**这些线**是垂直特征所在的坐标轴的。

小结：将一个降维的问题，转化为一个求目标函数最大值的问题

2

使用梯度上升法求解
PCA问题

目标：求 w ，使得 $f(X) = \frac{1}{m} \sum_{i=1}^m (X_1^{(i)}w_1 + X_2^{(i)}w_2 + \dots + X_n^{(i)}w_n)^2$ 最大

（用 $f(x)$ 不用 $J(x)$ 是因为 $J(x)$ 通常用来描述损失函数）

此处使用梯度上升法，关键看怎么求梯度，其中 $\mathbf{x}^{(i)}$ 是非监督学习提供的样本信息，另外从目标函数中没有 y 的信息也可以看出，只有 x 的信息，表示的是非监督。

$$\nabla f = \begin{pmatrix} \frac{\partial f}{\partial w_1} \\ \frac{\partial f}{\partial w_2} \\ \dots \\ \frac{\partial f}{\partial w_n} \end{pmatrix} = \frac{2}{m} \begin{pmatrix} \sum_{i=1}^m (X_1^{(i)}w_1 + X_2^{(i)}w_2 + \dots + X_n^{(i)}w_n)X_1^{(i)} \\ \sum_{i=1}^m (X_1^{(i)}w_1 + X_2^{(i)}w_2 + \dots + X_n^{(i)}w_n)X_2^{(i)} \\ \dots \\ \sum_{i=1}^m (X_1^{(i)}w_1 + X_2^{(i)}w_2 + \dots + X_n^{(i)}w_n)X_n^{(i)} \end{pmatrix} = \frac{2}{m} \begin{pmatrix} \sum_{i=1}^m (X^{(i)}w)X_1^{(i)} \\ \sum_{i=1}^m (X^{(i)}w)X_2^{(i)} \\ \dots \\ \sum_{i=1}^m (X^{(i)}w)X_n^{(i)} \end{pmatrix}$$

2

使用梯度上升法求解PCA问题

可对上式进行向量化处理，成为矩阵之间的运算，这样可以不使用for循环

$$\begin{aligned} & \frac{2}{m} \cdot (X^{(1)}w, X^{(2)}w, X^{(3)}w, \dots, X^{(m)}w) \cdot \begin{pmatrix} X_1^{(1)} & X_2^{(1)} & X_3^{(1)} & \dots & X_n^{(1)} \\ X_1^{(2)} & X_2^{(2)} & X_3^{(2)} & \dots & X_n^{(2)} \\ X_1^{(3)} & X_2^{(3)} & X_3^{(3)} & \dots & X_n^{(3)} \\ \dots & \dots & \dots & \dots & \dots \\ X_1^{(m)} & X_2^{(m)} & X_3^{(m)} & \dots & X_n^{(m)} \end{pmatrix} \\ &= \frac{2}{m} \cdot (Xw)^T \cdot X \end{aligned}$$

m x n : m行表示m个样本，n列表示有n个特征

2

使用梯度上升法求解PCA问题

Xw 是一个向量，向量一般用列向量表示， X 是一个 $m \times n$ 的矩阵，而 w 是 $n \times 1$ 的列向量，二者相乘之后是一个 $m \times 1$ 的列向量，此处写成了行向量，所以需要转置，而右侧矩阵本身就是 X

Xw 的转置是一个向量 $1 \times m$ ，而 X 是一个 $m \times n$ 的矩阵，得到的结果是一个 $1 \times n$ 的向量，而梯度想要的是一个 $n \times 1$ 的梯度，则此处需要再将 $(Xw)^T \cdot X$ 转置，即得

$$\frac{2}{m} \cdot X^T (Xw)$$

2

使用梯度上升法求解 PCA问题

由此推导出：

$$\nabla f = \frac{2}{m} \begin{pmatrix} \sum_{i=1}^m (X^{(i)} w) X_1^{(i)} \\ \sum_{i=1}^m (X^{(i)} w) X_2^{(i)} \\ \dots \\ \sum_{i=1}^m (X^{(i)} w) X_n^{(i)} \end{pmatrix} = \frac{2}{m} \cdot X^T (Xw)$$



谢谢