




机器学习

Machine Learning
(多领域交叉学科)



目录

CONTENTS

1

机器学习简介

2

机器学习相关基础知识

3

K近邻算法 (KNN)

4

线性回归法

5

逻辑回归法

6

主成分分析法 (PCA)

7

支持向量机算法 (SVM)

8

决策树算法

9

集成学习和随机森林

课程安排

总学时：40学时

周学时：4 学时（1-10周）

考核形式：考试

课程考核


成绩构成

考试 + 专题讨论 + 作业 + 平时表现

- 考试：笔试（60%）
- 专题讨论：任务驱动模式-完成3个算法的研究（20%）
- 作业：课后作业（10%）
- 平时表现：课堂表现+考勤（10%）

1

机器学习概述




人工智能：机器展现的人类智能

机器学习：计算机利用已有的数据(经验)，得出了某种模型，并利用此模型预测未来的一种方法。

深度学习：实现机器学习的一种技术

机器学习是人工智能的一个实现途径，深度学习是机器学习的一个方法发展而来。



人工智能的两段寒冬分别是1974-1980年和1987-1993年

1

机器学习界执牛耳者




杨立昆（Yann LeCun）Facebook首席人工智能科学家和纽约大学教授
杰弗里·欣顿（Geoffrey Hinton）加拿大多伦多矢量研究所首席科学顾问。
Google副总裁和工程研究员。多伦多大学计算机科学荣誉教授
本吉奥（Bengio）蒙特利尔大学终身教授，蒙特利尔大学机器学习研究所负责人
共同获得了2018年计算机科学的最高奖项——**ACM图灵奖**。

Andrew Ng
中文名吴恩达，斯坦福大学副教授，前“百度大脑”的负责人与百度首席科学家。

1

机器学习界国内泰斗



李航, 现任字节跳动科技有限公司人工智能实验室总监, 北京大学、南京大学客座教授, IEEE 会士, ACM 杰出科学家, CCF 高级会员。
代表作: 《统计学习方法》



周志华, 南京大学计算机科学与技术系主任、人工智能学院院长。
代表作: 《机器学习》(西瓜书)

1

机器学习界青年才俊



陈天奇,陈天奇是机器学习领域著名的青年华人学者之一，本科毕业于上海交通大学ACM班，博士毕业于华盛顿大学计算机系。
主要贡献：设计了XGBoost算法。



何恺明，本科就读于清华大学，博士毕业于香港中文大学多媒体实验室。2016年，加入Facebook AI Research (FAIR) 担任研究科学家。
主要贡献：设计了ResNets

1

知名人工智能企业榜单

编码	企业名称	人工智能技术	应用领域	所属国家	成立时间	资本市场状态	市值/估值/融资额
1	Microsoft (微软)	计算机视觉技术、自然语言处理技术等	办公	美国	1975年	上市	市值1.21万亿美元
2	Google (谷歌)	计算机视觉技术、自然语言处理技术等	综合	美国	1998年	上市	市值9324亿美元
3	Facebook (脸书)	人脸识别、深度学习等	社交	美国	2004年	上市	市值5934亿美元
4	百度	计算机视觉技术、自然语言处理技术、知识图谱等	综合	中国	2001年	上市	市值438亿美元
5	大疆创新	图像识别技术、智能引擎技术等	无人机	中国	2006年	战略融资	估值210亿美元
6	商汤科技	计算机视觉技术、深度学习	安防	中国	2014年	D轮融资	估值70亿美元
7	旷视科技	计算机视觉技术等	安防	中国	2011年	D轮融资	估值40亿美元
8	科大讯飞	智能语音技术	综合	中国	1999年	上市	市值108亿美元
9	Automation Anywhere	自然语言处理技术、非结构化数据认知	企业管理	美国	2003年	B轮融资	估值68亿美元
10	IBM Watson (IBM沃森)	深度学习、智适应学习技术	计算机	美国	1911年	上市	市值1198亿美元
11	松鼠AI 1对1	智适应学习技术、机器学习	教育	中国	2015年	A轮融资	估值11亿美元
12	字节跳动	跨媒体分析推理技术、深度学习、自然语言处理、图像识别	资讯	中国	2012年	Pre-IPO轮融资	估值750亿美元
13	Netflix (网飞)	视频图像优化、剧集封面图片个性化、视频个性化推荐	媒体及内容	美国	1997年	上市	市值1418亿美元
14	Graphcore	智能芯片技术、机器学习	芯片	英国	2016年	D轮融资	估值17亿美元
15	NVIDIA (英伟达)	智能芯片技术	芯片	美国	1993年	上市	市值1450亿美元
16	Brainco	脑机接口	教育、医疗、智能硬件	美国	2015年	天使轮融资	融资额600万美元
17	Waymo	自动驾驶	交通	美国	2016年	C轮融资	估值1050亿美元
18	ABB Robotics	机器人及自动化技术	机器人	瑞士	1988年	上市	市值514亿美元
19	Fanuc (发那科)	机器人技术	制造	日本	1956年	上市	市值362亿美元
20	Preferred Networks	深度学习、机器学习技术	物联网	日本	2016年	C轮融资	估值20亿美元

课程导学

什么是机器学习

机器学习专门研究计算机怎样模拟或实现人类的学习行为，以获取新的知识或技能，重新组织已有的知识结构使之不断改善自身的性能。它是人工智能核心，是使计算机具有智能的根本途径。

最早的机器学习应用 – 垃圾邮件分辨

□ 传统的计算机解决问题思路：

- 编写规则，定义“垃圾邮件”，让计算机执行
- 对于很多问题，规则很难定义
- 规则在不断变化


图像识别

课程导学



课程导学

人脸识别




课程导学

数字识别



MNIST数据集

课程导学



模式识别

计算机视觉



数据挖掘



机器学习

语音识别



统计学习



自然语言处理



1

机器学习算法的体系化研究

课程方法

- 深入理解算法的基本原理
- 实际使用算法解决真实场景的问题
- 对不同算法进行对比实验
- 对同一算法的不同参数进行对比试验
- 对部分算法底层进行编写

课程要求

学科领域

机器学习是一门多领域交叉学科，涉及概率论、统计学、逼近论、线性代数、高等数学等多门学科。

技术栈

语言：Python 3

框架：Scikit-learn

其他：numpy, matplotlib, ...

IDE：Jupyter Notebook



课程要求

课程所使用的数据集

框架：Scikit – learn 内置数据集或通过Scikit – learn可以直接下载的数据集

5.2. Toy datasets

scikit-learn comes with a few small standard datasets that do not require to download any file from some external website.

<code>load_boston</code> ([return_X_y])	Load and return the boston house-prices dataset (regression).
<code>load_iris</code> ([return_X_y])	Load and return the iris dataset (classification).
<code>load_diabetes</code> ([return_X_y])	Load and return the diabetes dataset (regression).
<code>load_digits</code> ([n_class, return_X_y])	Load and return the digits dataset (classification).
<code>load_linnerud</code> ([return_X_y])	Load and return the linnerud dataset (multivariate regression).
<code>load_wine</code> ([return_X_y])	Load and return the wine dataset (classification).
<code>load_breast_cancer</code> ([return_X_y])	Load and return the breast cancer wisconsin dataset (classification).


These datasets are useful to quickly illustrate the behavior of the various algorithms implemented in the scikit. They are however often too small to be representative of real world machine learning tasks.

2

机器学习的类型

机器学习是现阶段解决很多人工智能问题的主流方法，作为一个独立的方向，正处于高速发展之中。最早的机器学习算法可以追溯到20世纪初，到今天为止，已经过去了100多年。从1980年机器学习称为一个独立的方向开始算起，到现在也已经过去了近40年。在这100多年中，经过一代又一代人的努力，诞生出了大量经典算法。

总体上，机器学习算法可以分为有监督学习、无监督学习、半监督学习、强化学习4种类型。其中半监督学习可以认为是有监督学习与无监督学习的结合，因此也可以说机器学习分为3种类型。现在介绍一些有代表性算法。



2

有监督学习

有监督学习通过训练样本学习得到一个模型，然后用这个模型进行推理。

例如，如果要识别各种水果的图像，则需要用人工标注（即标好了每张图像所属的类别，如苹果，梨，香蕉）的样本进行训练，得到一个模型，接下来，就可以用这个模型对未知类型的水果进行判断，这称为预测。




MNIST数据集

- 银行已经积累了一定的客户信息和他们信用卡的信用情况
- 医院已经积累了一定的病人信息和他们最终确诊是否患病的情况
- 市场积累了房屋的基本信息和最终成交的金额
-

2

有监督学习




线性判别分析 (LDA) 是Fisher发明的，其历史可以追溯到1936年，那时候还没有机器学习的概念。这是一种有监督的数据降维算法，它通过线性变换将向量投影到低维空间中，保证投影后同一种类型的样本差异很小，不同类的样本尽量不同。

贝叶斯分类器起步于1950年，基于贝叶斯决策理论，它把样本分到后验概率最大的那个类。

logistic回归的历史同样悠久，可以追溯到1958年。它可以直接预测出一个样本属于正样本的概率，在广告点击率预估、疾病诊断等问题上得到了广泛应用。

2

有监督学习




感知器模型是一种线性分类器，是人工神经网络的前身，诞生于1958年，但它过于简单，甚至不能解决异或问题，因此不具有实用价值，更多的起到了思想启蒙的作用，为后面的算法奠定了思想上的基础。

kNN算法诞生于1967年，这是一种基于模板匹配思想的算法，虽然简单，但很有效，至今仍在被使用。

在1980年之前，这些机器学习算法都是零碎化的，不成体系。但它们对整个机器学习的发展所起的作用不能被忽略。

2

有监督学习




从1980年开始，机器学习才真正成为一个独立的方向。在这之后，各种机器学习算法被大量的提出，得到了快速发展。决策树的3种典型实现：ID3，CART，C4.5是1980年代到1990年代初期的重要成果，虽然简单，但可解释性强，这使得决策树至今在一些问题上仍被使用。

1986年诞生了用于训练多层神经网络的真正意义上的反向传播算法，这是现在的深度学习中仍然被使用的训练算法，奠定了神经网络走向完善和应用的基础。

2

有监督学习




1989年，LeCun设计出了第一个真正意义上的卷积神经网络，用于手写数字的识别，这是现在被广泛使用的深度卷积神经网络的鼻祖。

在1986到1993年之间，神经网络的理论得到了极大的丰富和完善，但当时的很多因素限制了它的大规模使用。

1990年代是机器学习百花齐放的年代。在1995年诞生了两种经典的算法-SVM和AdaBoost，此后它们纵横江湖数十载。

2

有监督学习




SVM代表了核技术的胜利，这是一种思想，通过隐式的将输入向量映射到高维空间中，使得原本非线性的问题能得到很好的处理。而AdaBoost则代表了集成学习算法的胜利，通过将一些简单的弱分类器集成起来使用，居然能够达到惊人的精度。

现在大红大紫的LSTM在2000年就出现了，在很长一段时间内一直默默无闻，直到2013年，与深度循环神经网络整合，在语音识别上取得成功。

2

有监督学习




随机森林出现于2001年，与AdaBoost算法同属集成学习，虽然简单，但在很多问题上效果却出奇的好，因此现在还在被大规模使用。

距离度量学习算法于2009年发表，是一篇经典之作，算是经典机器学习算法中的新生代，之后这种通过机器学习得到距离函数的想法被广泛的研究，出现不少相关论文。

2

有监督学习



从1980年开始到2012年深度学习兴起之前，有监督学习得到了快速的发展，这有些类似于春秋战国时代，各种思想和方法层出不穷，相继登场。另外，没有一种机器学习算法在大量的问题上取得压倒性的优势，这和现在的深度学习时代很不一样。

2

无监督学习

相比较于有监督学习，无监督学习的发展一直很缓慢，至今仍未取得大的突破。下面按照聚类和数据降维两类问题对这些无监督学习算法进行介绍。

◆ 聚类 (Clustering)


◆ 如何将教室里的学生按爱好、身高划分为5类？

◆ 降维 (Dimensionality Reduction)

◆ 如何将原高维空间中的数据点映射到低维度的空间中？

2

无监督学习




聚类算法的历史与有监督学习一样悠久。层次聚类算法出现于1963年，这是非常符合人的直观思维的算法，现在还在使用。它的一些实现方式，包括SLINK，CLINK则诞生于1970年。

k均值算法可谓所有聚类算法中知名度最高的，其历史可以追溯到1967年，此后出现了大量的改进算法，也有大量成功的应用，是所有聚类算法中变种和改进型最多的。

2

无监督学习




大名鼎鼎的EM算法诞生于1977年，它不光被用于聚类问题，还被用于求解机器学习中带有缺数(亏数)数据的各种极大似然估计问题。

Mean Shift算法在1995年就被用于聚类问题，和DBSCAN算法，OPTICS算法一样，同属于基于密度的聚类算法。

谱聚类算法是聚类算法家族中年轻的小伙伴，诞生于2000年左右，它将聚类问题转化为图切割问题，这一思想提出之后，出现了大量的改进算法。

2

无监督学习



数据降维算法


PCA算法诞生于1901年，是比较经典算法，这个算法比第一台真正的计算机的诞生早了40多年。

LDA算法的思路同PCA一致，即通过某种线性投影，将原本高维空间中的一些数据，映射到更低维度的空间中。

此后的近100年里，数据降维在机器学习领域没有出现太多重量级的成果。直到1998年，核PCA作为非线性降维算法的出现。这是核技术的又一次登台，与PCA的结合将PCA改造成了非线性的降维算法。

2

无监督学习




从2000年开始，机器学习领域刮起了一阵流形学习的旋风，这种非线性方法是当时机器学习中炙手可热的方向，这股浪潮起始于局部线性嵌入LLL。此后，拉普拉斯特征映射、局部保持投影、等距映射等算法相继提出。流形学习在数学上非常优美，但遗憾的是没有多少公开报道的成功的应用。

t-SNE是降维算法中年轻的成员，诞生于2008年，虽然想法很简单，效果却非常好

2

无监督学习




概率图模型

概率图模型是机器学习算法中独特的一个分支，它是图与概率论的完美结合。在这种模型中，每个节点表示随机变量，边则表示概率。因为晦涩难以理解，让很多人谈虎色变，但如果你悟透了这类方法的本质，其实并不难。

赫赫有名的隐马尔可夫模型诞生于1960年，在1980年代，它在语音识别中取得了成功，一时名声大噪，后来被广泛用于各种序列数据分析问题，在循环神经网络大规模应用之前，处于主导地位。

2

无监督学习




马尔可夫随机场诞生于1974年，也是一种经典的概率图模型算法。

贝叶斯网络是概率推理的强大工具，诞生于1985年，其发明者是概率论图模型中的重量级人物，后来获得图灵奖。

条件随机场是概率图模型中相对年轻的成员，被成功应用于中文分词等自然语言处理等领域，是序列标注问题的有力建模工具。

2


深度学习



虽然真正意义上的人工神经网络诞生于1980年，反向传播算法、卷积神经网络、LSTM等也提出较早，但遗憾的是神经网络在过去很长时间内并没有得到大规模的成功应用，在与SVM等机器学习算法的较量中处于下风。原因主要有：算法本身的问题，如梯度消失问题，导致深层网络难以训练；训练样本数的限制；计算能力的限制；直到2006年，情况才慢慢改观。

2


深度学习



对神经网络改进一直在进行着，在深度学习的早期，自动编码器和受限玻尔兹曼机被广泛的研究，典型的改进和实现的算法有：去噪自动编码器、收缩自动编码器、变分自动编码器、DBN、DBM等，虽然改进算法较多，但还是没有真正得到成功应用。

2


深度学习



后来在语音识别中大显身手的CTC（连接主义时序分类）早在2006年就被提出，然而生不逢时，在后面一直默默无闻。情况真正被改变发生在**2012年**，Alex网络的成功使得深度神经网络卷土重来。在这之后，卷积神经网络被广泛的应用于机器视觉的各类问题。循环神经网络则被用于语音识别、自然语言处理等序列预测问题。整合了循环神经网络和编码器-解码器框架的seq2seq技术，巧妙地解决了大量的实际应用问题。而GAN作为深度生成模型的典型代表，可以生成逼真的图像，得到了不可思议的效果，是目前深度学习中热门的研究方向。

2


深度学习



历史选择了神经网络并非偶然，它有万能逼近定理作为保障，可以拟合闭区间上任意一个连续函数。另外，还可以人为控制网络的规模，用来拟合非常复杂的函数，这是其他机器学习算法不具备的。深度学习的出现，让图像、语音等感知类问题取得了真正意义上的突破，离实际应用已如此之近。

2


强化学习



相比有监督学习和无监督学习，强化学习在机器学习领域的起步更晚。虽然早在1980年代就出现了时序差分算法，但对于很多实际问题，无法用表格的形式列举出所有的状态和动作，因此这些抽象的算法无法大规模实用。

2

强化学习



神经网络与强化学习的结合，即深度强化学习，才为强化学习带来了真正的机会。在这里，深度神经网络被用于拟合动作价值函数即Q函数，或者直接拟合策略函数，这使得我们可以处理各种复杂的状态和环境，在围棋、游戏、机器人控制等问题上真正得到应用。神经网络可以直接根据游戏画面，自动驾驶汽车的摄像机传来的图像，当前的围棋棋局，预测出需要执行的动作。其典型的代表是DQN这样的用深度神经网络拟合动作价值函数的算法，以及直接优化策略函数的算法。

3


机器学习开发流程



3

机器学习如何解决问题

- 给定数据的预测问题
 - ✓ 数据清洗/特征选择
 - ✓ 确定算法模型/参数优化
 - ✓ 结果预测
- 不能解决什么
 - ✓ 大数据存储/并行计算
 - ✓ 做一个机器人



3


机器学习开发流程

数据搜集

数据清洗

特征工程

数据建模



数据集

- 著名的鸢尾花数据 https://en.wikipedia.org/wiki/Iris_flower_data_set



Iris setosa

山鸢尾(setosa)



Iris versicolor

变色鸢尾(versicolor)



Iris virginica

维吉尼亚鸢尾(virginica)

3

机器学习基础概念

数据集

Iris Plants Database

=====

Notes

Data Set Characteristics:

:Number of Instances: 150 (50 in each of three classes)

:Number of Attributes: 4 numeric, predictive attributes and the class

:Attribute Information:

- sepal length in cm
- sepal width in cm
- petal length in cm
- petal width in cm
- class:
 - Iris-Setosa
 - Iris-Versicolour
 - Iris-Virginica



山鸢尾(setosa)

变色鸢尾(versicolor)

维吉尼亚鸢尾(virginica)


3

机器学习基础概念

数据集

数据

萼片长度	萼片宽度	花瓣长度	花瓣宽度	种类
5.1	3.5	1.4	0.2	se (0)
7.0	3.2	4.7	1.4	ve (1)
6.3	3.3	6	2.5	vi (2)



山鸢尾(setosa)

变色鸢尾(versicolor)

维吉尼亚鸢尾(virginica)

3

机器学习基础概念

数据集

山鸢尾(setosa)

变色鸢尾(versicolor)

维吉尼亚鸢尾(virginica)

萼片长度	萼片宽度	花瓣长度	花瓣宽度	种类
5.1	3.5	1.4	0.2	se (0)
7.0	3.2	4.7	1.4	ve (1)
6.3	3.3	6	2.5	vi (2)

- 数据整体叫数据集 (data set)
- 每一行数据称为一个样本(sample)
- 除最后一列，每一列表达样本的一个特征(feature)

第*i*个样本行写作 $x^{(i)}$ ，第*i*个样本第*j*个特征值写作： $x_j^{(i)}$

3

机器学习基础概念

数据集

山鸢尾(setosa)

变色鸢尾(versicolor)

维吉尼亚鸢尾(virginica)

萼片长度	萼片宽度	花瓣长度	花瓣宽度	种类
5.1	3.5	1.4	0.2	se (0)
7.0	3.2	4.7	1.4	ve (1)
6.3	3.3	6	2.5	vi (2)

X y

- 数据整体叫数据集 (data set)
- 每一行数据称为一个样本(sample)
- 除最后一列，每一列表达样本的一个特征(feature)
- 最后一列，称为标记(label)

第 i 个样本行写作 $x^{(i)}$ ，第 i 个样本第 j 个特征值写作： $x_j^{(i)}$ 第 i 个样本的标记写作 $y^{(i)}$

3

机器学习基础概念

数据集

萼片长度	萼片宽度	花瓣长度	花瓣宽度	→ 特征	→ 特征向量 $X^{(i)}$
5.1	3.5	1.4	0.2		
7.0	3.2	4.7	1.4		$\begin{pmatrix} (X^{(1)})^T \\ (X^{(2)})^T \\ (X^{(3)})^T \\ \dots \end{pmatrix}$
6.3	3.3	6	2.5		

$$\begin{pmatrix} 5.1 \\ 3.5 \\ 1.4 \\ 0.2 \end{pmatrix}$$


特征向量：每一行对应的特征的值组成的向量，标记为 $x^{(i)}$ 这样的形式。

3

机器学习基础概念


数据集

数据



- 这里取鸢尾花数据集的前两个特征，萼片长度和萼片宽度，其中，萼片长度作为横轴，萼片宽度作为纵轴，对于每一个样本来说，在坐标系中会表示成一个点。


数据集



- 特征空间：每一个样本的本质就是这些特征所组成的一个空间中的一个点，这个空间即为 feature space；
- 在这个平面特征空间中，其中红色代表一类鸢尾花，蓝色代表另外的一类鸢尾花，判断一个给定的花，究竟是哪一类鸢尾花，本质就是在这个特征空间进行一个切分；
- 不同的机器学习算法切分的精度不一样。

数据集

特征可以很抽象



- 图像，每一个像素点都是特征
- 28×28 的图像有 $28 \times 28 = 784$ 个特征
- 如果是彩色图像特征更多

- 著名的MNIST数据集，在这个数据集中每一个手写数字，都是一个 28×28 的一个图像，那么对于每一个图像，它就是一个样本，每一个样本拥有 $28 \times 28 = 784$ 个特征。
- 这些像素点对应的灰度值的大小来描述这个图像，把这些特征放进机器学习算法中，研究这个特征和最终这些特征所表达的那个数值，比如说对于这个图像来说，就是5这个数它们之间的这个关系。

4

机器学习的主要任务

本课程内容大部分算法是研究**分类**和**回归**任务，都属于有监督学习算法，而无监督学习主要是辅助监督学习的进行。

- ✓ **分类**

- ✓ KNN、逻辑回归、朴素贝叶斯、决策树、支持向量机

- ✓ **回归：**

- ✓ 线性回归

- ✓ **聚类**

- ✓ K-Means

- ✓ **关联分析**

- ✓ Apriori、FP-growth

- ✓ **降维**

- ✓ 主成分分析 (PCA)

- ✓ **深度学习**

4

机器学习的主要任务

如果只是预测一个类别值，则称为**分类问题**；

如果要预测出一个实数，则称为**回归问题**。

◆ 分类 (Classification)

◆ 身高1.65m，体重100kg的男人肥胖吗？

◆ 根据肿瘤的大小、患者的年龄来判断良性或恶性？

◆ 回归 (Regression、Prediction)

◆ 如何预测沈阳浑南的房价？

◆ 如根据一个人的学历、工作年限、所在城市、行业等特征来预测这个人的收入。



4

机器学习的分类任务

二分类

分类任务



- 判断邮件是垃圾邮件；不是垃圾邮件
- 判断发放给客户信用卡有风险；没有风险
- 判断病患良性肿瘤；恶性肿瘤
- 判断某支股票涨；跌

4

机器学习的分类任务

多分类

分类任务



- 数字识别
- 图像识别
- 判断发放给客户信用卡的风险评级



4

机器学习的分类任务

多分类


- 一些算法只支持完成二分类的任务
- 但是多分类的任务可以转换成二分类的任务
- 有一些算法天然可以完成多分类任务

4

机器学习的分类任务

分类任务

多标签分类



对于这个图片大家可以看到它不仅仅要对图片中的人物进行划分，甚至对图片中的物体进行划分，比如说机器识别出这个图片中有一个女人，她穿着一白色的裙子，拿着一个网球拍等等，综合这些信息，就可以得到这个图片的一个语义，推测出这个图片中可能表现的的是一个网球女运动员；多标签分类，是一个比较前沿的研究课题。

4

机器学习的分类任务

思考题：分析以下数据

房屋面积 (平方米)	房屋年龄 (年)	卧室数量 (间)	最近地铁站距离 (千米)	价格 (万元)
80	3	1	10	300
120	8	3	5	500
200	5	4	12	700

4

机器学习的回归任务

预测结果是一个连续数字的值，而非一个类别。


- 房屋价格
- 市场分析
- 学生成绩
- 股票价格

有一些算法只能解决回归问题，有一些算法只能解决分类问题，而有一些算法既能解决回归问题，又能解决分类问题。一般情况下，回归任务可以简化成分类任务

4

机器学习的主要任务

想一想：




4

机器学习的主要任务

无监督学习

给机器的训练数据没有任何“标记”或者“答案”




4

机器学习的主要任务

无监督学习

作用一：对没有“标记”的数据进行分类 → 聚类分析



如：在京东或淘宝上浏览或购买不同的商品信息而留下的一些行为数据，其实这些平台对于我们每个人都是同等对待的，起初我们是没有被“标记”的，随着我们购物的行为越来越多，我们便被“标记”

- 理性消费者
- 冲动消费者
- 注重性价比
- 追求商品质量

4


机器学习的主要任务

无监督学习

作用二：对没有“标记”的数据进行 → 降维处理

特征提取：信用卡的信用评级和人的胖瘦无关
现实中样本的特征比较复杂

特征压缩：在尽量小的损失情况下，将高维特征压缩成低维特征
主成分分析 (PCA)



手写识别：28X28 = 784个特征
经过特征压缩以后只需要几十个或者十几个特征就可以了。


4

机器学习的主要任务

无监督学习

作用二：对没有“标记”的数据进行 → 降维处理

降维处理的意义：方便可视化




4

机器学习的主要任务

无监督学习

作用三：对没有“标记”的数据进行 → 异常检测



4

机器学习的主要任务

半监督学习 一部分数据有“标记”或者“答案”，另一部分数据没有

更常见：各种原因产生的标记缺失


通常都先使用无监督学习手段对数据做处理，之后使用监督学习手段做模型的训练和预测

5


机器学习不同视角



不同行业的人以为我做的事情



父母以为我做的事情



朋友以为我做的事情

$$\begin{aligned} \frac{\partial}{\partial w} L(w, b, \alpha) &= w - \sum \alpha_i y_i x_i = 0, \quad w = \sum \alpha_i y_i x_i \\ \frac{\partial}{\partial b} L(w, b, \alpha) &= \sum \alpha_i y_i = 0 \end{aligned}$$

代入 $L(w, b, \alpha)$

$$\begin{aligned} \min L(w, b, \alpha) &= \frac{1}{2} \|w\|^2 + \sum_{i=1}^m \alpha_i (-y_i (w^T x_i + b) + 1) \\ &= \frac{1}{2} w^T w - \sum_{i=1}^m \alpha_i y_i w^T x_i - b \sum_{i=1}^m \alpha_i y_i + \sum_{i=1}^m \alpha_i \\ &= \frac{1}{2} w^T \sum \alpha_i y_i x_i - \sum_{i=1}^m \alpha_i y_i w^T x_i + \sum_{i=1}^m \alpha_i \\ &= \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \alpha_i y_i w^T x_i \\ &= \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i,j=1}^m \alpha_i \alpha_j y_i y_j (x_i x_j) \end{aligned}$$

再把 max 问题转成 min 问题:

$$\begin{aligned} \max \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i,j=1}^m \alpha_i \alpha_j y_i y_j (x_i x_j) &= \min \frac{1}{2} \sum_{i,j=1}^m \alpha_i \alpha_j y_i y_j (x_i x_j) - \sum_{i=1}^m \alpha_i \\ \text{s.t. } \sum_{i=1}^m \alpha_i y_i &= 0, \end{aligned}$$

程序员以为我做的事情




我自己以为我做的事情

```
import xgboost as xgb
import numpy as np
```

实际上我做的事情

5

数据决定一切



通过这张图可以看出，各种不同算法在输入的数据量达到一定级数后，都有相近的高准确度。于是诞生了机器学习界的名言：

成功的机器学习应用不是拥有最好的算法，而是拥有最多的数据！



谢谢