





机器学习

Machine Learning
(多领域交叉学科)

1

过拟合和欠拟合

回归模型的拟合程度分析：



首先回顾一下模型训练的过程，模型参数的训练实际上就是一个不断迭代，寻找到一个方程 $H_{\theta}(x)$ 来拟合数据集。然而到这里，我们只知道需要去拟合训练集，但拟合的最佳程度我们并没有讨论过。

左边图：拟合程度比较低，显然这样的 $H_{\theta}(x)$ 并不是想求的。连训练集的准确率如此低，那么测试集肯定也不高，也就是模型的泛化能力不高。


右边图：拟合程度非常高，甚至每一个点都能通过 $H_{\theta}(x)$ ，这个就是希望得到的 $H_{\theta}(x)$ ？首先，数据集中无法避免的存在着许多噪声，而在理想情况下，希望噪声对模型训练的影响为0。而如果模型将训练集中每一个点都精准描述出来，显然包含了许多噪声点，在后续的测试集中得到的准确率也不高。另一方面，太过复杂的 $H_{\theta}(x)$ 直接导致函数形状并不平滑，不能起到预测的作用，“回归”模型也丧失了其预测能力（也就是模型泛化能力），显然这不是想要的。

中间图：展现的是最适合的拟合程度，不过于复杂或过于简单，并且能够直观的预测函数的走向。虽然它在测试集的中准确度不及右图高，但在测试集中得到的准确率是最高的，同时泛化能力也是最强的。

1

过拟合和欠拟合

分类模型的拟合程度分析：



欠拟合

过拟合

正合适

1

过拟合和欠拟合

总结：

- 1、欠拟合：泛化能力差，训练样本集准确率低，测试样本集准确率低。
- 2、过拟合：泛化能力差，训练样本集准确率高，测试样本集准确率低。
- 3、合适的拟合：泛化能力强，训练样本集准确率高，测试样本集准确率高。

1

欠拟合的处理

欠拟合原因：

1、训练样本数量少

当特征不足或者现有特征与样本标签的相关性不强时，模型容易出现欠拟合。

2、模型复杂度过低

简单模型的学习能力较差

3、参数还未收敛就停止循环

欠拟合的解决办法：

1、增加样本数量

通过挖掘组合特征等新的特征，往往能够取得更好的效果。

2、增加模型参数，提高模型复杂度

通过增加模型的复杂度可以使模型拥有更强的拟合能力。例如，在线性模型中添加高次项，在神经网络模型中增加网络层数或神经元个数等。

3、增加循环次数

4、查看是否是学习率过高导致模型无法收敛

1

过拟合的处理

过拟合原因：

- 1、数据噪声太大
- 2、特征太多
- 3、模型太复杂

过拟合的解决办法：

- 1、获得更多的训练数据（清洗数据）

使用更多的训练数据是解决过拟合问题最有效的手段，因为更多的样本能够让模型学习到更多更有效的特征，减小噪声的影响。


- 2、降维，即丢弃一些不能帮助正确预测的特征。可以是手工选择保留哪些特征，或者使用一些模型选择的算法来帮忙（例如PCA）。

- 3、减少模型参数，降低模型复杂度

使用正则化(regularization)技术，保留所有的特征，但是减少参数的大小（magnitude），它可以改善或者减少过拟合问题。

1

过拟合的处理



通过这张图可以看出，各种不同算法在输入的数据量达到一定级数后，都有相近的高准确度。于是诞生了机器学习界的名言：

成功的机器学习应用不是拥有最好的算法，而是拥有最多的数据！

1

正则化 Regularization

“正则化”是机器学习中的一个术语。

首先了解一下正则性（regularity），正则性衡量了函数光滑的程度，正则性越高，函数越光滑。（光滑衡量了函数的可导性，如果一个函数是光滑函数，则该函数无穷可导，即任意 n 阶可导）。

为什么要正则化？

当模型过于复杂时，容易造成过拟合，因此为了减小过拟合，要将一部分参数置为0，最直观的方法就是限制参数的个数，但这是一个NP难题，因此可以通过正则化来解决，即减小模型参数大小或参数数量，缓解过拟合。

1

正则化 Regularization

具体来说，正则化是用来防止模型过拟合而采取的手段。对代价函数增加一个限制条件，限制其较高次的参数大小不能过大。使用回归模型举例如下：

$$h_{\theta}(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2^2 + \theta_3 x_3^3 + \theta_4 x_4^4$$

正是那些高次项导致了过拟合的产生，所以如果能让这些高次项的系数接近于0的话，就能很好的拟合了，因此，对代价函数 $J(\theta)$ 进行修改如下：

$$\min_{\theta} J(\theta) = \min_{\theta} \frac{1}{2m} \left[\sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 + 1000\theta_3^2 + 10000\theta_4^2 \right]$$

在方程中增加了两个限制条件，分别对 θ_3 和 θ_4 进行限制，不能让其过高。很直观的看出，要想使 $J(\theta)$ 最小化，不仅仅需要 $h_{\theta}(x^{(i)})$ 足够拟合 $y^{(i)}$ ，同时还需要减少 θ_3 和 θ_4 。

1

正则化 Regularization

范数是向量的某种抽象长度，它满足通常意义上的长度的三个基本性质：

- 非负性： $\|\vec{x}\| \geq 0$;
- 齐次性： $\|c \cdot \vec{x}\| = |c| \cdot \|\vec{x}\|$;
- 三角不等式： $\|\vec{x} + \vec{y}\| \leq \|\vec{x}\| + \|\vec{y}\|$ 。

常用的范数：

- L_0 -范数： $\|\vec{x}\|_0 = \#(i)$, with $x_i \neq 0$;
- L_1 -范数： $\|\vec{x}\|_1 = \sum_{i=1}^d |x_i|$;
- L_2 -范数： $\|\vec{x}\|_2 = \left(\sum_{i=1}^d x_i^2 \right)^{1/2}$;
- L_p -范数： $\|\vec{x}\|_p = \left(\sum_{i=1}^d x_i^p \right)^{1/p}$;
- L_∞ -范数： $\|\vec{x}\|_\infty = \lim_{p \rightarrow +\infty} \left(\sum_{i=1}^d x_i^p \right)^{1/p}$ 。

1

正则化 Regularization

范数的非负性，使得它有可能作为正则项使用。

若使用 $\|w\|_p$ 作为正则项，则我们说使用了 L_p -正则项 (the L_p -regularizer)。

什么是正则化？

正则化即规范化。规则化就是说给损失函数加上一些限制，通过这种规则去规范接下来的循环迭代过程，不要自我膨胀。又称为惩罚项，惩罚的是模型的参数，其值恒为非负。

λ 是正则化系数，是一个超参数，调节惩罚的力度，越大则惩罚力度越大。

通式：

$$\text{Loss_with_regularization} = \text{loss}(w, x) + \lambda f(w)$$

正则化的本质就是给参数引入一个先验分布，L1假设拉普拉斯分布，L2假设高斯分布（正态分布）

1

正则化 Regularization

L1：对参数进行一次约束，会形成稀疏解

$$Loss_with_regularization = loss(w, x) + \lambda |w|$$

L2正则化：对参数进行二次约束，参数w变小，但不为零，不会形成稀疏解。

$$Loss_with_regularization = loss(w, x) + \lambda \|w\|_2^2 \quad \text{其中 } \|w\|_2^2 = \sqrt{\sum_i w_i^2} \text{ 即 } w \text{ 的二范数}$$

L1、L2正则化本质都是使其参数w等于或趋向于0，也可以设计一种方法使其趋向于一个非零值（但一般不这么做）。

1

正则化 Regularization

L_1 正则化 : $J(w) = \frac{1}{2} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)})^2 + \lambda \sum_{j=1}^n |w_j|$, Lasso Regression (Lasso回归)

L_2 正则化 : $J(w) = \frac{1}{2} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)})^2 + \lambda \sum_{j=1}^n w_j^2$, Ridge Regression (岭回归)

Elastic Net : $J(w) = \frac{1}{2} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)})^2 + \lambda (\rho \cdot \sum_{j=1}^n |w_j| + (1 - \rho) \cdot \sum_{j=1}^n w_j^2)$ (弹性网络)



其中：

- λ 为正则化系数，调整正则化项与训练误差的比例， $\lambda > 0$ 。
- $1 \geq \rho \geq 0$ 为比例系数，调整 L_1 正则化与 L_2 正则化的比例。

1

正则化 Regularization


什么是稀疏解？

简单说，稀疏解就是当有很多维度的特征，其中很多特征参数都为0，只有一小部分特征参数为1，即这些特征参数向量为 $(0, 0, 0, 0, 0, 1, 0, 0, 0, 1, 0, 0, 0, 0, 0, \dots)$

为什么L1正则化比L2正则化更易产生稀疏解？

1

正则化 Regularization




L_1 正则化是指在损失函数中加入权值向量 w 的绝对值之和， L_1 的功能是使权重稀疏

L_1 正则化可以产生稀疏模型

上图中的蓝色轮廓线是没有正则化损失函数的等高线，在同一条线上其取值相同，且越靠近中心其值越小，中心的蓝色点为最优解，左图、右图分别为 L_1 、 L_2 正则化给出的限制。

可以看到在正则化的限制之下， L_2 正则化给出的最优解 w^* 是使解更加靠近原点，也就是说 L_2 正则化能降低参数范数的总和。 L_1 正则化给出的最优解 w^* 是使解更加靠近某些轴，而其它的轴则为0，所以 L_1 正则化能使得到的参数稀疏化。



在损失函数中加入权值向量 w 的平方和， L_2 的功能是使权重平滑。

L_2 正则化可以防止过拟合



谢谢